https://hjfy.top/arxiv/2508.12752

深度研究：自主研究智能体综述

WENLIN ZHANG, City University of Hong Kong, China

XIAOPENG LI, City University of Hong Kong, China

YINGYI ZHANG, Dalian University of Technology & City University of Hong Kong, China

PENGYUE JIA, City University of Hong Kong, China

YICHAO WANG, Huawei Noah’s Ark Lab, China

HUIFENG GUO, Huawei Noah’s Ark Lab, China

YONG LIU, Huawei Noah’s Ark Lab, China

XIANGYU ZHAO†, City University of Hong Kong, China

大语言模型（LLMs）的快速发展推动了能够自主执行复杂任务的智能体系统的发展。尽管其能力令人印象深刻，但 LLMs 仍受限于其内部知识边界。

为克服这些限制，提出了深度研究范式，其中智能体主动参与规划、检索和综合，以生成基于网络证据的全面且可靠的分析报告。在本综述中，我们系统地概述了深度研究流水线，该流水线包含四个核心阶段：规划、问题构建、网络探索和报告生成。针对每个阶段，我们分析了关键技术挑战，并对为解决这些问题而开发的代表性方法进行了分类。此外，我们总结了近期针对深度研究优化技术与基准的进展。最后，我们讨论了开放性挑战和有前景的研究方向，旨在为构建更强大且可信的深度研究智能体绘制发展路线图。

CCS Concepts: • **信息系统 → 信息检索**; • **计算方法学 → 自然语言处理**.

Additional Key Words and Phrases: Deep Research, Deep Search, Large Language Models, Information Retrieval, Autonomous Agents

---

†Corresponding Author.

Authors’ Contact Information: Wenlin Zhang, wl.z@my.cityu.edu.hk, City University of Hong Kong, China; Xiaopeng Li, xiaopli2-c@my.cityu.edu.hk, City University of Hong Kong, China; Yingyi Zhang, yingyizhang@mail.dlut.edu.cn, Dalian University of Technology & City University of Hong Kong, China; Pengyue Jia, jia.pengyue@my.cityu.edu.hk, City University of Hong Kong, China; Yichao Wang, wangyichao5@huawei.com, Huawei Noah’s Ark Lab, China; Huifeng Guo, huifeng.guo@huawei.com, Huawei Noah’s Ark Lab, China; Yong Liu, liu.yong6@huawei.com, Huawei Noah’s Ark Lab, China; Xiangyu Zhao†, xianzhao@cityu.edu.hk, City University of Hong Kong, China.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.

Manuscript submitted to ACM

ACM Reference Format:
Wenlin Zhang, Xiaopeng Li, Yingyi Zhang, Pengyue Jia, Yichao Wang, Huifeng Guo, Yong Liu, and Xiangyu Zhao†. 2025. 深度研究：自主研究智能体综述. In *Proceedings of Make sure to enter the correct conference title from your rights confirmation email (Conference acronym 'XX).* ACM, New York, NY, USA, 21 pages. https://doi.org/XXXXXXX.XXXXXXX

1 引言

大模型（LLMs），例如 GPT-4 [43]、Qwen3 [88] 和 DeepSeek-R1 [22]，已取得显著进展。这些进展使大模型能够作为通用语言智能体。然而，大模型仍受限于其内部知识边界，从而在动态或专业场景中的有效性受到限制。

为克服这些局限性，提出了检索增强生成（RAG）方法，通过访问外部信息源来增强大模型的推理能力。RAG 系统从大规模语料库中检索相关文档，并基于检索到的内容来引导大模型的生成。尽管 RAG 框架提升了事实准确性和适应性，但它将模型限制为被动地消费检索内容，而无法参与更深层次的探索或推理。随着大模型持续获得规划、工具使用和反思性推理等智能体能力，从被动检索向主动、目标驱动的外部知识源交互转变的趋势日益明显。这一转变标志着一种新范式——*智能体搜索*的兴起。

在智能体搜索范式中，一种新兴的显著方法是*深度搜索*，其中智能体动态地参与规划、问题构建和网络探索，以迭代方式检索与不断演进的任务目标相一致的信息。尽管深度搜索显著提升了智能体获取和 contextualize 知识的能力，但在完成需要综合与推理的复杂研究任务时仍显不足。为弥补这一差距，引入了*深度研究*范式，该范式结合了探索与结构化分析及迭代生成。此范式使智能体能够将检索到的证据转化为连贯、真实且与目标一致的输出，满足高层次研究工作流的需求。深度研究过程通常包含四个相互关联的阶段：

规划。该阶段涉及将高层次的研究问题分解为结构化的子目标或子任务。智能体必须决定搜索的内容、顺序，以及中间信息如何支持后续的综合。与传统的逐步提示不同，规划需要在任何检索或生成开始之前，先生成一个明确的、任务感知的路线图。

问题生成。给定一个子目标，智能体生成一个或多个检索查询，以捕捉特定且上下文相关的信息需求。这些查询在抽象程度、具体性和粒度上可能各不相同。与静态问题生成 [29] 相比，此阶段需要自适应地生成多样且互补的查询，以匹配不断演化的子目标。

网络探索。智能体通过网络 API 或基于浏览器的动作主动与外部源交互，以收集相关信息。此过程需要选择工具、发起查询、解析结果，并过滤噪声或冗余内容。与传统 RAG 流水线中的单次检索不同，网络探索是迭代且由智能体驱动的，能够实现对稀疏或分散证据的更深入覆盖。

报告生成。为了生成结构化的报告，智能体必须通过选择相关证据、有条理地组织内容，并确保一致性和完整性来整合检索到的信息。这一过程超越了抽取式或浅层生成，需要多源融合、话语层面的规划以及特定任务的格式化。

如图 1 所示，深度研究系统涉及多阶段任务和广泛的信息处理，这对智能体能力提出了逐步演进的需求。

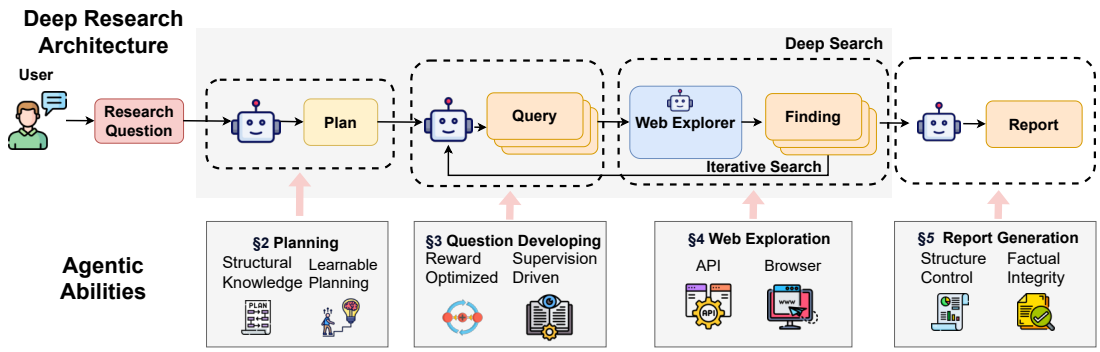

Fig. 1. **深度研究系统的概述**。

因此，为了充分发挥深度研究系统的优势，我们根据关键能力需求，对主要挑战及相应的解决方案进行了梳理：

- **规划**：*给定一个研究问题，如何在执行前构建一个有效且可解释的研究计划？*规划是深度研究中的第一阶段和基础环节，将用户意图转化为可执行的步骤，如子问题的构建和证据的检索。其核心挑战在于将宽泛或模糊的问题分解为结构化的计划，尤其是在开放式研究目标下。与立即响应的智能体不同，研究智能体必须对中间步骤和执行路径进行推理。这要求规划机制既能适应不同类型的问题，又具备人类可检查的可解释性。我们将其定义为 *规划模块*（见第 2 节），该模块生成结构化、目标驱动的计划，以指导后续的推理和检索。
- **问题生成**: *在规划阶段给出一个子目标后，如何制定出有效且多样化的查询，以平衡精确性与覆盖范围*。在深度研究智能体中，问题生成对于引导检索过程以获取相关信息至关重要。然而，由于需要捕捉具体的信息需求同时确保主题的广泛覆盖，生成既精确又全面的查询具有挑战性。解决方案通常涉及自适应查询生成策略，其中智能体根据研究任务演进的上下文动态制定查询。通过与搜索环境交互，采用强化学习等技术来优化查询的有效性；而无需强化学习的方法，如监督微调或基于启发式的方法，则提供了增强查询多样性和相关性的替代途径。我们将这一过程定义为 *问题生成模块*（见第 3 节），该模块基于规划阶段的子目标生成一组有针对性的、情境化的查询。
- **网络探索**: *给定搜索计划和查询，如何高效地检索最相关且可信的信息，同时过滤掉网络上的噪声、冗余或冲突信息？*在深度研究工作流中，高效定位并在线获取精确信息对于生成高质量的研究报告至关重要。近期的工作包括自主网络检索智能体，它们通过爬取超链接来收集相关内容 [24, 41, 90, 101]，以及基于 API 的方法，直接查询搜索引擎 [1, 2, 6, 7]。我们将此过程称为 *网络探索模块*（见第 4节），该模块根据输入的研究查询，从多样化来源检索相关信息。
- **报告生成**: *在获取与目标研究问题相关的证据后，如何生成保持事实完整性的连贯且结构化的报告*。该阶段对于将零散的知识转化为全面的分析报告至关重要。然而，报告生成在结构

控制和事实完整性方面面临挑战。为应对这些挑战，近期方法引入了结构感知规划和约束引导生成以确保布局的一致性，并采用基于证据的建模来保证事实的可靠性。我们将这一过程定义为 报告生成模块（见第 5 节），其基于深度研究智能体在网页探索阶段收集的信息，生成结构化且可信的报告。

针对这些挑战，我们提出了一种以能力为中心的深度研究智能体综述，特别关注核心能力——如规划、检索、推理和报告生成——如何被独立优化并协同集成。与列举完整系统流水线不同，我们剖析了深度研究背后的模块化能力，分析其技术瓶颈与协调挑战。为此，我们首先分析构建深度研究智能体的关键障碍；随后回顾各模块中的代表性方法；最后突出新兴趋势，如基于推理的检索、结构化报告生成以及自演化智能体。相较于以往综述，我们的工作提供了更细粒度、模块化的视角。例如，Huang 等人 [26] 侧重系统架构与未来路线图，而 Xu 等人 [84] 提供了任务与工具的广泛枚举性概述。相比之下，我们的分类体系聚焦于能力的形成与整合，旨在揭示方法间的深层联系，并为演进的设计范式提供洞见。

2 规划

深度研究系统越来越强调设立专门的规划阶段，以协调复杂且具有长期目标的任务。现代智能体不再仅依赖于反应式的逐步提示，而是通过明确的规划来决定在执行前应采取哪些动作或子任务。这一规划过程有助于克服纯粹反应式提示的局限性，提升任务分解能力，更系统地引导信息检索与推理，并减少因试错策略导致的失败。

Definition 2.1 (Planning). 在深度研究智能体中，规划指的是智能体将用户查询和先验知识转化为包含中间子目标或动作的结构化研究计划的过程。形式上，给定初始研究问题 q_0 和智能体上下文 $\mathcal{K}$ ，由 θ 参数化的规划模型 $\mathcal{M}^{\text{plan}}$ 生成一个计划：

$$\mathcal{P} = \mathcal{M}^{\text{plan}}(q_0, \mathcal{K}; \theta), \tag{1}$$

其中 $\mathcal{P} = [s_1, s_2, \ldots, s_n]$ 表示一系列引导下游执行的子目标或工具调用步骤。

这些规划策略可能包括世界模型仿真 [21]、模块化设计搜索 [62]、类人推理轨迹合成 [69]，或智能体自我优化 [45]。为了更好地理解规划策略的多样性，我们在表 1中总结了代表性方法，并按其规划策略进行分类。该规划是动态生成的，能够根据任务复杂度、资源可用性或用户意图进行自适应调整。它在面向研究的网络智能体中充当高层次目标与低层次执行之间的桥梁。

2.1 基于结构化世界知识的规划

基于网络的智能体研究日益凸显出利用结构化世界知识——从学成的潜在世界模型到显式的图结构——来指导长周期决策的重要性。早期证据表明，大模型（LLMs）可作为隐式世界模型，为目标导向推理提供充分的环境先验 [20]。基于这一洞察，Simulate Before Act 框架引入了

表 1. 深度研究智能体中规划方法的分类。

Planning	Category	Related Works
Planning with Structured World Knowledge	Planning via simulation	WebDreamer [20], Simulate Before Act [21]
	Planning via modularity	Webpilot Zhang et al. [96], WKM [52],Plan-and-Act Erdogan et al. [17]
	Planning via adaptation	Thought of Search [32], MPO [83]
Planning as a Learnable Process	Planning via space exploration	Agentsquare [62], Agent-E Abuelsaad et al. [4]
	Planning via self-training	Patel et al. [45], InSTA Trabucco et al. [71]
	Planning via preference modeling	MindSearch Chen et al. [11], SimpleDeepSearcher [69], Search-in-the-Chain [85], WEPO [37], MPO [83]

一个显式的仿真阶段，使智能体能够在执行前于脑海中推演候选动作轨迹并评估其可行性，从而提升鲁棒性与适应性 [21]。

结构化的多模块流水线进一步丰富了这一范式。WebPilot 将网络探索任务划分给由战略规划器协调的专用子智能体，展示了基于共享世界表示构建的分布式规划如何提升任务效率 [96]。Qiao 等引入外部知识图谱以约束推理路径，体现了显式建模环境结构的 *知识引导规划* [52]。对于时序扩展的任务，Erdogan 等将初始计划与迭代优化步骤相结合，以在长时程内保持一致性 [17]。

效率考量也塑造了当代方法：Katz 等. 量化了推理操作的计算成本，并提出一种考虑效率的规划策略，以在深思熟虑的程度与资源使用之间取得平衡 [32]。最后，Xiong 等. 提出了 *元规划最优化*（MPO），这是一种元学习方法，能够自适应地在多样的网络环境中调整规划策略，从而在世界模型保真度与策略灵活性之间形成闭环 [83]。综合来看，这些工作将结构化知识转化为前瞻性和计算上审慎的网络智能体规划的基础。

2.2 规划作为可学习的过程

另一种互补的研究轨迹将*规划机制本身*作为学习的主要对象，使智能体能够通过搜索、反馈和大规模训练迭代地优化其决策过程。AgentSquare 通过在庞大的配置空间中进行架构搜索，自动构建任务适配的规划流水线，从而摒弃了手工设计的启发式方法 [62]。Agent-E 从导航任务中提炼出可复用的组件，展示了如何通过系统级分解涌现出稳健的行为 [4]。

通过交互反馈实现自我改进也已被证明是有效的：Patel 等展示了基于大语言模型的智能体仅通过部署经验即可优化其规划启发式方法，而无需人工干预 [45]。将这一理念进行缩放，Trabucco 等提出了互联网规模的训练流水线，能够在大量任务分布上泛化规划行为，将注意力从单任务最优化转向终身适应性 [71]。

增强推理的规划机制进一步丰富了这一可学习范式。MindSearch 模拟类人的搜索策略以深化规划轨迹 [11]，而 SimpleDeepSearcher 则为信息检索任务合成多跳推理路径 [69]。Search-in-the-Chain 通过基于中间搜索结果动态更新动作选择，实现了检索与规划之间的环路闭合 [85]。

WEPO 根据用户界面偏好定制规划，在 UI 元素层面优化动作序列 [37]。MPO 最初用于跨环境的元学习，同样展示了智能体如何通过高阶梯度更新来优化规划策略 [83]。

这些研究共同将规划重新概念化为一种可学习、可演化的能力，强调持续的自我改进和任务驱动的适应性，而非静态执行。

2.3 讨论

规划阶段已成为近期深度研究智能体的关键组成部分，不仅为后续推理提供了结构，还在开放性任务中带来了可解释性和控制力。一个显著优势是显式、结构化的规划输出的出现——例如推理链、搜索命令或子目标草图——这些有助于智能体避免短视或重复的行为。另一个令人鼓舞的趋势是，智能体能够随时间学习并优化其规划策略。通过交互反馈、元学习或接触大规模任务分布，智能体正逐步自我调整其规划流程，在动态网络环境中展现出越来越稳健的行为。

然而，仍存在一些重要局限。首先，当前大模型生成的计划往往脆弱，对模糊的研究问题或表述不充分的目标缺乏鲁棒性。即使采用结构化格式，计划的内部一致性也无法保证，幻觉步骤可能导致错误在后续环节中传播。其次，尽管规划模块日益模块化且可学习，其评估仍较为粗略，通常依赖最终任务的准确率而非规划质量本身，这使得诊断规划失败或有意义地比较不同策略变得困难。第三，许多系统将每个研究问题视为孤立的问题，未能利用共享结构或可迁移的策略，从而限制了智能体在跨任务中积累可泛化规划知识的能力。

事实上，越来越多的研究致力于解决这些挑战——从引入 DeepResearch Bench [16] 等标准化基准以评估报告的忠实度和引用准确率，到采用 DeepResearcher [98] 等强化学习框架，促进在网页环境中的迭代自我反思和规划能力提升。但关键局限依然存在，尤其是在处理分歧、确保长程一致性以及跨任务迁移规划策略方面。

3 问题开发

为了支持深度研究任务，例如多步推理和信息综合，仅依赖单一静态查询往往是不够的。相反，系统必须动态生成更具针对性、上下文相关性或经过分解的查询，以从检索模块或网络中获取有用的证据。这一过程被称为 查询发展，对于引导超越关键词匹配、面向任务的信息检索策略至关重要。

3.1 定义

Definition 3.1 (Question Developing). 问题构建指的是将结构化计划 $\mathcal{P} = [s_1, \dots, s_n]$ 中的每个子目标 s_i 转换为一系列搜索查询 $\mathcal{Q}_i = \{q_{i,1}, q_{i,2}, \dots\}$ 的过程。该过程由整体计划 $\mathcal{P}$ 、当前子目标 s_i 和累积的证据 $\mathcal{E}$ 所引导，其中证据 $\mathcal{E}$ 包含从前序查询中检索到的信息。形式上，给定一个查询生成模型 $\mathcal{M}^{\text{ask}}$ 及其参数 θ ，子目标 s_i 的查询生成为

$$\mathcal{Q}_i = \mathcal{M}^{\text{ask}}(\mathcal{P}, s_i, \mathcal{E}; \theta). \tag{2}$$

生成和更新证据集 $\mathcal{E}$ 的检索过程在第 4 节中详细说明。

问题生成方法可根据最优化方法分为两类：奖励最优化方法，其中查询表述过程通过由奖励信号引导的试错探索进行最优化；以及监督驱动方法，其依赖于监督微调或手动设计的策略，而不涉及显式的奖励驱动查询最优化。这些方法的分类如表 2 所示，按训练范式和关键建模策略进行组织。在本节余下部分，我们将形式化问题生成的概念，并探讨实例化该过程的代表性策略。

表 2. 深度研究智能体中问题生成方法的分类

Optimization	Category	Related Works
Reward-Optimized Methods	Rewards for format and accuracy	DeepResearcher [98], EvolveSearch [93], R1-Searcher [66], Search-R1 [31], ZeroSearch [68], MaskSearch [80], DeepRetrieval [30]
	Multi-dimensional reward	InForage [51], OTC-PO [74], IKEA [28], AutoRefine [65], R-Search [97], MMSearch-R1 [77], VRAG-RL [75]
Supervision-Driven Methods	Multi-agent systems	ManuSearch [25], Search-o1 [35], SearchAgent-X [89]
	Supervision optimization	ReasonRAG [95]

3.2 奖励优化方法

强化学习（RL）通过与搜索环境的交互以及来自特定任务奖励的反馈，为优化查询生成策略提供了一个原则性框架。与需要标注查询-响应对的监督微调不同，基于奖励优化的方法使智能体能够探索查询策略，并根据最终任务结果（如答案准确率、检索覆盖度或效率）自适应地调整搜索时机和方式。

许多基于强化学习的问题生成方法中常见的设计选择是，仅根据输出格式的正确性和最终答案的准确率来定义奖励。这些方法将检索和推理视为黑箱组件，仅优化输出是否符合指定格式并得出正确答案。这种做法简化了奖励信号，使得在噪声环境或模拟环境中进行训练更容易扩展。

例如，DeepResearcher[98] 和 EvolveSearch[93] 使用二进制格式奖励和基于 token 的 F1 回报奖励，通过 GRPO 训练多智能体系统与真实或模拟的搜索 API 交互。R1-Searcher[66] 进一步引入了分阶段训练框架，第一阶段仅奖励格式合规性和搜索使用，第二阶段则整合基于 F1 的答案质量奖励。类似地，Search-R1[31] 强制采用严格的格式模板（如 <think>、<search>、<information>、<answer>），并通过 PPO 或 GRPO 优化基于精确匹配的奖励。ZeroSearch[68] 在模拟情景下遵循相同原则，用学成的搜索模拟器替代真实的搜索 API，从而在无需任何真实查询成本的情况下实现基于课程 rollout 的奖励学习。DeepRetrieval[30] 在检索指标（如 Recall@K 或 NDCG@K）上定义奖励，使查询生成与检索性能对齐。最后，MaskSearch[80] 完全基于掩

码跨度恢复（通过检索增强的答案预测）来定义奖励，在预训练过程中将格式和准确率整合为统一的奖励函数。这些奖励设计有助于引导智能体生成不仅语法正确，而且更有可能检索到与答案相关的内容的查询，尤其是在噪声较大或监督较弱的环境中。

与仅基于输出格式和答案正确性定义奖励的方法不同，第二类问题生成方法整合了更丰富、多维度的奖励信号，能够更好地反映交互式推理与搜索的复杂性 [66]。这些奖励函数不仅考虑生成的答案内容，还关注答案的获取方式——惩罚不必要的搜索，奖励具有信息量的中间步骤，或根据智能体的内部知识与外部知识边界进行调整。

InForage[51] 在基于结果的奖励基础上增加了 *信息增益*（真实知识的覆盖）和一个 *效率惩罚*，以减少冗余的推理跳转。OTC-PO[74] 引入了成本感知的奖励机制，对过度使用工具进行惩罚，旨在最小化外部调用的同时保持正确性。IKEA [28] 进一步结合了 *知识边界感知奖励*，对仅使用内部知识解决“简单”问题的智能体给予正向反馈，并对不必要的或无成效的外部搜索进行惩罚。其他研究则更强调对多轮轨迹的奖励塑造。AutoRefine[65] 不仅评估最终答案的质量，还评估从检索文档中提取的中间精炼过程的完整性。R-Search[97] 和 MMSearch-R1[77] 将答案正确性、证据质量和格式合规性相结合，支持跨模态的结构化推理。最后，VRAG-RL [75] 将这一思想扩展到视觉-语言情景，通过针对图像选择、视觉注意力一致性以及最终答案质量的细粒度奖励来优化视觉搜索动作。

这些奖励优化方法展示了在嘈杂、动态且高风险的研究环境中，学习自适应且可解释的查询开发策略的可行性。它们为智能体提供了基础，使其能够在具体情境中推理查询的价值，并通过强化反馈不断改进自身行为。

3.3 监督驱动方法

与依赖强化学习最优化的奖励驱动方法不同，监督驱动的方法通过监督微调、基于规则的分解或结构化的多智能体工作流来构建问题生成策略。这些方法避免了强化学习的复杂性和不稳定性，转而利用人类示范、任务特定启发式方法或架构优化来指导有效查询策略的开发。

一条研究方向致力于构建结构化的多智能体系统，将问题求解过程分解为模块化的角色。ManuSearch[25] 实现了一个透明的开源框架，其中包含分离的智能体分别负责规划子问题、执行外部网络搜索以及从 HTML 内容中提取结构化证据。每个智能体基于确定性或监督规则运行，并通过多轮协作完成复杂的查询分解与信息综合。类似地，Search-o1[35] 和 SearchAgent-X [89] 探索了系统层面的优化，例如自适应检索调度和高效的批量处理，以提升检索增强推理的吞吐量和响应速度，而无需改变潜在语言模型的行为。

其他方法探索模仿学习或基于偏好的最优化来监督问题生成过程。ReasonRAG [95] 用对中间步骤的细粒度反馈替代了稀疏的结果仅监督。通过蒙特卡洛树搜索（MCTS）探索推理轨迹，并使用 DPO 对它们进行排序，ReasonRAG 能够在不依赖试错强化的情况下识别出更有效的规划行为。这使得模型能够从较少的训练样本中更高效地学习如何交错搜索与推理。

这些监督驱动的方法在问题生成方面具有多项实际优势：它们能够实现更可控的查询生成，通过模仿人工编写的示例或遵循基于规则的模板，通常生成结构良好且语义准确的查询。由于在训练过程中避免与嘈杂或昂贵的搜索环境交互，这些方法更易于优化，并在低资源情景下表现出更高的稳定性。此外，其显式的监督机制使得在应对规划错误或特定任务失败时，更容易诊断并调整查询行为。然而，其有效性往往受限于可用示范的质量和覆盖范围；若示范缺乏多样性，生成的查询可能无法适应未见过的子目标或新颖的推理情境。总体而言，这些方法通过在数据效率、查询一致性及开发简便性优先的情景中提供更安全、更可解释的解决方案，与奖励优化方法形成互补。

3.4 讨论

问题生成模块是深度研究智能体的核心组件，负责将子目标转化为一系列具体的检索查询。这些查询需准确反映子目标的意图，同时具备足够的广度，以从外部源中检索到全面且相关的信息。该模块本质上是智能体探索信息空间的起点，直接影响后续检索与答案生成的质量。目前，在问题生成领域的主要趋势包括基于奖励优化的方法和基于监督驱动的方法。基于奖励优化的方法通过与搜索环境的交互动态调整查询策略，利用反馈信号（如检索结果的相关性）来提升效率与准确率。另一方面，基于监督驱动的方法，如基于规则的查询生成或多智能体协作系统，则通过预设逻辑或协同工作来增强查询的多样性和具体性。这些方法均旨在使智能体能够更智能地“提问”，以满足复杂的科研需求。

尽管取得了进展，现有方法仍存在显著不足。首先，生成的查询往往过度依赖子目标的清晰度；一旦子目标模糊或含糊不清，查询质量会显著下降，导致信息检索出现偏差。其次，许多系统在生成查询时缺乏上下文连贯性，例如未能有效整合之前的查询历史或任务背景，从而产生重复或冗余的问题。最后，当前方法在处理开放性问题时表现不佳，倾向于生成过于狭窄的查询，无法涵盖广泛的可能性信息，限制了智能体的探索能力。

4 网页探索

深度研究工作流，从科学发现、文献综述到事实核查及其他专家调查，都高度依赖于从网络上海量且异构的信息中检索出精确、上下文相关且可信的证据。然而，由于相关信息在成千上万的网页中分布稀疏，设计能够准确定位并提取最有用内容的智能体仍然是一个关键挑战。

Definition 4.1 (Web Exploration). 在深度研究的背景下，网页探索是从在线资源中检索最相关信息的过程。这可能涉及 (i) 部署一个智能体递归地跟随超链接并过滤内容，或 (ii) 调用搜索引擎 API 以获取相关网页文档的排序结果。给定查询 $\mathcal{Q}_i$ ，网页检索器 $\mathcal{R}$ ，参数化为 θ 的网页智能体 $\mathcal{M}^{\text{web}}$ ，以及开放网页语料库 $\mathcal{H}$ ，网页探索过程定义为

$$\mathcal{D} = \mathcal{M}^{\text{web}}\big(\mathcal{R}, \mathcal{Q}_i, \mathcal{H}; \theta\big), \tag{3}$$

其中 $\mathcal{D}$ 表示最终检索到的文档集合。

现代的网络检索方法大致可分为两类：(1) 基于网络智能体的系统：自主智能体系统，能够执行浏览、点击和提取信息等操作，其方式类似于人类研究人员进行网络检索。(2) 基于 API 的检索系统：直接使用当前的网络搜索引擎（例如，Google 搜索、Bing 搜索等），让开发者可将排序后的文档或片段直接引入研究流水线。两类代表性方法的总结如表 3 所示。

表 3. 深度研究智能体中网络探索方法的分类。

Information Source	Category	Related Works
Web-based	Web scraping and crawling	Scrapy [59], BeautifulSoup [55]
	Browser-based web agents	WebGPT [41], Selenium [60]
	Multimodal web agents	WebVoyager [24], MM-ReAct [90], WebArena [101]
API-based	Industrial search engines	Bing [1], X posts [3], Google [2]
	Domain-specific search engines	Reportify [54], YanXueZhiDe [12], CNKI [13], DuckSearch [67], BraveSearch [7], Bocha [6]

4.1 网络检索智能体

网络检索智能体是能够从网络中提取信息的自主系统，构成了深度研究系统的关键组成部分。这些智能体已从简单的信息提取工具演进为复杂的多模态系统，能够导航复杂的交互式内容，并整合来自多种来源的信息。

基于浏览器的自主网络智能体. 由人工智能驱动的浏览器智能体标志着深度研究中基于网页的信息获取方式的根本性转变。与静态爬虫不同，这些智能体通过真实或模拟的浏览器动态导航网页界面，根据所遇到的内容做出上下文相关的决策，以确定探索哪些路径。WebGPT [41] 首次采用基于文本的浏览器，将 HTML 转换为结构化表示，使语言模型能够发出高层级命令，例如 `Find` *keyword* 来检索相关段落。更复杂的实现则利用 Selenium [60] 通过真实浏览器直接查询文档对象模型或执行自定义 JavaScript。Agent-E 是紧凑表示方法的典范，构建可访问性树以保留语义结构的同时去除冗余元素。这些智能体通过文本表示感知内容，并以编程方式执行动作——点击链接、填写表单或触发交互元素。尽管在文本密集型研究任务中表现良好，但当关键信息以视觉布局或嵌入式可视化形式呈现时，该方法便失效，从而推动了向多模态智能体的过渡。

多模态网络智能体. 当前的网络检索智能体集成了视觉感知能力，能够处理文本内容和视觉线索——解析图表、识别界面模式并理解空间信息的组织方式。这一能力对于需要分析数据可视化或导航视觉复杂的研究数据库的深度研究至关重要。目前已出现两种方法：专用提示框架（如 MM-ReAct [90]）和完全集成的视觉-语言智能体。两者均结合渲染后的截图与文本元数据，实现对网页的全面表示。WebVoyager [24] 采用 GPT-4V，将截图分析与 HTML 处理相结合，在真实世界基准测试中实现了 59% 的任务成功率，显著优于仅依赖文本的基准方法。

MM-ReAct [90] 将截图直接嵌入推理链中，支持基于视觉反馈的迭代动作执行。Sightseer [34] 从截图中重建 HTML/CSS，而 WebArena [101] 则为多种界面模式提供了全面的评估框架。

这些多模态智能体展现出关键的研究能力——能够带引用地回答复杂问题，并整合异构来源的发现。尽管在鲁棒性和可靠性方面仍面临挑战，但进展表明，未来的智能体将能以专家级策略导航网络知识，彻底改变研究人员获取和综合信息的方式。随着这些系统日趋成熟，人类的工作重心将从机械的信息搜集转向更高层次的分析与洞察生成。

4.2 基于 API 的检索系统

基于 API 的检索能够快速将外部知识融入深度研究流水线。通过暴露标准化的端点，成熟的工业级搜索引擎可以无缝集成，从而获得可靠且可信的搜索结果。OpenAI DeepResearch [44] 利用微软 Bing 的网络搜索基础设施 [1]，发起查询、提取段落、生成后续查询、对候选文档进行排序，甚至执行沙箱代码。Grok DeepSearch [81] 运行其自身的爬虫，并通过特权访问 X 平台帖子 [3] 补充公开网络数据。Gemini DeepResearch [18] 调用谷歌专有的搜索栈 [2]，而 Perplexity DeepResearch [46] 采用混合方案，融合类似 Bing 的网络索引与 Perplexity 的 Sonar API，后者提供 BM25、关键词和稠密向量重排序功能。多个领域专用系统进一步缩小范围，聚焦于特定语料库，例如 Reportify [54] 集成授权的市场研究报告和权威财经新闻，而 YanXueZhiDe [12] 在 CNKI [13] 数据库上提供学术检索。相比之下，开源框架通常依赖第三方引擎，如 DuckSearch [67]、BraveSearch [7] 或 Bocha [6]。

4.3 讨论

网络探索对于深入研究至关重要，它通过两种主要方式从广阔的网络中获取精确且相关的证据：网络检索智能体擅长动态导航网页界面，模拟人类浏览行为以访问交互式或未被索引的内容，因此在应对复杂问题时具有高度适应性。然而，其资源消耗大且缺乏实时可信度评估，存在显著缺陷。相比之下，基于 API 的系统能够快速高效地访问来自成熟搜索引擎的预索引数据，确保可靠性，但常常忽略小众或动态内容。尽管这两种方法单独使用均具有效性，但由于与上游研究阶段（如问题构建和证据规划）脱节，难以完全适应特定研究需求。

未来网络探索的前景在于混合架构，这类架构通过整合两种方法的优势，系统性地解决这些核心挑战。先进系统必须包含专门用于证据提取、正确性验证和内容质量评估的模块，以实现快速初始检索，并随后进行深入的交互式分析。多模态处理和实时验证框架的关键进展将对于跟上不断演变的网络环境至关重要。通过为不同系统模块建立稳健的分类框架，并系统性地应对这些技术挑战，网络探索将发展成为深度研究的全面基础，提供更精确且可信的证据检索能力。

5 报告生成

在深度研究中，生成任务超越了传统的问答任务，旨在生成一份全面且具有分析性的报告。这一过程被称为 报告生成，其目标是将从网络上检索到的零散信息整合成结构连贯、逻辑清晰且忠实于潜在证据的报告。

Definition 5.1 (Report Generation). 在深度研究智能体的背景下，报告生成指的是智能体整合网络信息并生成综合性报告的过程。给定初始研究问题 q_0 ，研究计划 $\mathcal{P}$ ，检索到的文档 $\mathcal{D}$ ，以及网络智能体 $\mathcal{M}_\theta$ ，报告生成过程可定义为

$$\mathcal{Y} = \mathcal{M}_\theta(q_0, \mathcal{P}, \mathcal{Q}, \mathcal{D}) \tag{4}$$

其中 $\mathcal{Y}$ 表示生成的报告。

报告生成方法大致可分为两类：结构控制和 事实完整性。(1) 结构控制侧重于将多步推理和检索内容组织成连贯的格式，通常依赖于规划感知生成或约束引导生成。(2) 事实完整性旨在确保生成的报告忠实于检索到的证据，通常通过接地机制或生成后验证来实现。每类中的代表性方法总结见表 4。

表 4. 深度研究智能体中人工制品生成方法的分类。

Field	Category	Representative Works
Structure Control	Planning-based Generation	Agent Laboratory [58], AI Scientist v2 [87], LongEval [78], LongWriter [5], LongDPO [49]
	Constraint-guided Generation	WebThinker [36], Suri [47], Wan et al. [73]
	Structural-aware Evaluation	Long2RAG [50], ExPerT [56], Long et al. [38], Kim et al. [33], Huang et al. [27]
Factual Integrity	Faithful Modeling	RAGSynth [63], BRIDGE [15], Zhou et al. [102], Shi et al. [64]
	Conflict Reasoning	FaithfulRAG [94], DRAGged [8], Yuan et al. [92], Ying et al. [91]
	Factuality Evaluation	Face4RAG [86], SFR-RAG [42], Wallat et al. [72], FaithJudge [70], RAG-QA Arena [23], MT-RAIG [61]

5.1 结构控制

结构控制指的是生成在结构上连贯且全局一致的长文本输出。这类长文本输出通常涵盖多个部分，需要有效的规划、主题一致性以及版式遵循。近期研究从三个角度解决了这一问题：基于规划的生成、约束引导的生成以及结构感知的对齐。

基于规划的生成方法通过利用文档大纲或层次化分解，在生成前或生成过程中组织内容。Agent Laboratory [58] 采用段落级别的规划策略并结合结构感知提示，而 AI Scientist v2 [87] 则执行递归的树状结构规划以保持全局布局的一致性。与此同时，LongEval [78] 和 LongWriter [5]

也体现了这一方法，将生成过程分解为高层级的大纲规划和章节级别的综合生成。这种分层策略有助于在数千个 token 范围内保持连贯性。LongDPO [49] 进一步在每个生成步骤中引入基于批评的监督机制，确保局部生成结果与全局文档结构相一致。

约束引导生成旨在解码过程中强制执行特定的格式、风格或内容要求。WebThinker [36] 引入了章节感知的分解方法，连接了规划与生成阶段，使模型能够将结构化子任务映射到内容章节。Suri [47] 研究了在多种布局和风格约束下的指令微调，包括语气、结构和主题覆盖。Wan et al. [73] 提出了一种类人修订框架，反映了在约束条件下的真实写作动态。

结构感知评估为训练和事后对齐提供了关键信号。Long2RAG [50] 开发了关键点召回率指标，用以评估检索到的证据是否充分融入长文本回答中。ExPerT [56] 提出了考虑布局特异性完整性和可解释性的评估策略。类似地，Long et al. [38] 在训练过程中探索基于属性引导的对齐，以使生成结构与任务特定期望相一致。Kim et al. [33] 评估长上下文模型中的原文保真度，以检测结构漂移或不对齐现象，而 Huang et al. [27] 提出校准方法以纠正输出生成中的结构不一致性。

5.2 事实完整性

事实一致性是深度研究中报告生成的核心，生成内容必须准确反映检索到的证据。尽管 RAG 技术取得了进展，但在保持事实准确性、解决冲突证据和验证内容可靠性方面仍面临挑战。为应对这些问题，近期研究探索了三个关键方向：忠实建模、冲突消解和事实评估。

忠实建模专注于确保生成内容与已验证且上下文相关的证据保持一致。RAGSynth [63] 在已知事实变化下生成合成监督信号，提升了鲁棒性与可信度。BRIDGE [15] 在检索与生成之间提出一个验证层，以评估事实充分性。Shi et al. [64], Zhou et al. [102] 提出上下文感知的解码方法，优先考虑高置信度的证据片段，减少幻觉性补全，从而提升响应的事实准确性。

冲突消解在检索到的来源包含相互矛盾的主张时至关重要。FaithfulRAG [94] 引入了事实级别的冲突建模，以促进与一致检索事实的对齐。DRAGged [8] 通过检测和干预模型识别并缓解源间冲突。基于熵的解码策略 [92] 能够自适应地应对证据的不确定性，在输入模糊的情况下促进更可靠的生成。Ying et al. [91] 探索了大型语言模型在冲突提示下的行为，并通过行为调优提升冲突感知能力。

事实性评估提供了用于指导训练和评估生成可靠性的指标与基准。Face4RAG [86] 使用细粒度指标评估中文 RAG 系统中的归属一致性。SFR-RAG [42] 开发了上下文归属指标，以在段落层面衡量对齐程度。Wallat et al. [72] 区分表面正确性与真实来源忠实性。FaithJudge[70] 和 RAG-QA Arena [23] 构建了持续演进的排行榜和领域鲁棒性基准，用于长文本事实性评估。MT-RAIG [61] 将事实性评估扩展至结构化数据场景，例如多表洞察生成。

5.3 讨论

报告生成是深度研究的最后一步，将子问题中零散的证据整合为结构化且可信的报告。为确保报告质量，近期的研究主要聚焦于结构控制和事实完整性。结构控制技术采用基于规划的生成方法与约束引导的解码策略，常结合结构感知的评估与对齐机制。与此同时，事实完整性通过忠实建模实现，即让生成过程基于相关证据，以及冲突推理机制，以保证检索到的多个来源之间的一致性。这些方法共同致力于生成结构清晰、可靠的结果，以满足研究型任务的需求。

尽管取得了这些进展，深度研究中的报告生成方法仍处于早期阶段。现有大多数方法仅针对报告生成的孤立子技能，而未能与上游组件进行联合最优化。然而，有效的报告合成本质上与先验规划、问题构建和网络探索阶段紧密耦合，这种脱节成为主要限制因素。此外，当前的结构控制方法通常依赖于固定的提纲或静态规划策略，缺乏根据任务特定复杂度、证据分布或推理流程灵活调整的能力。在事实性方面，尽管某些方法提升了局部定位能力，但很少有方法能够建模跨多文档和多跳上下文的一致性，而这正是涉及长输入上下文和矛盾来源的科研场景中的关键需求。

6 最优化

6.1 工作流

深度研究工作流通常分为单智能体和多智能体系统。单智能体工作流将所有研究阶段整合到一个模型中，支持集成推理和端到端学习。相比之下，多智能体工作流将过程分解为专业化模块，促进并行执行、模块化最优化和更高的灵活性。

单智能体系统。单个大语言模型智能体负责整个流程。DeepResearcher [98]、WebThinker [36] 和 Search-R1 [31] 等系统通常采用单体工作流，其中智能体按顺序执行任务分解、查询生成、检索（通过工具或 API）以及最终成果合成。所有推理和决策均由同一模型内部管理，通常通过强化学习进行端到端训练。

多智能体系统。相比之下，多智能体系统将不同的智能体分配给流水线的不同阶段。规划智能体负责任务分解与子目标调度；查询智能体专注于生成多样化且上下文相关的查询；检索智能体与外部工具交互以收集证据；写作智能体则执行结构化综合。这种模块化分工在 AgentRxiv [57]、AI Scientist [39] 和 OpenResearcher [99] 等系统中均有体现，使得每个组件能够独立地专业化和优化，从而在复杂研究任务中实现并行性和灵活性。

6.2 参数最优化

有效的深度研究不仅依赖于系统架构，还依赖于通过针对复杂任务定制的训练范式来优化智能体行为。当前研究主要集中在三种优化方法上：*对比学习*、*强化学习*和 *课程训练*，每种方法均针对智能体协作与决策中的不同挑战。

对比学习。该方法通过对比成功与失败的轨迹，教导智能体区分有效与无效行为，尤其在工具使用（如检索、搜索和摘要）方面表现突出。例如，*Avatar* [79] 通过训练智能体识别何时以及如何调用外部资源，提升了多步推理中的准确率。
强化学习。 RL 方法用于微调智能体的长期规划与决策能力，基于检索准确率和最终成果质量的奖励信号进行优化。诸如 *Search-O1* [35] 和 *Learning-to-Search* [9] 的系统利用强化学习促进复杂研究工作流中有效问题构建与文档获取。
课程训练。为应对逐步复杂的任务，课程训练采用分阶段的学习流水线，使智能体先掌握基础技能，再进阶至完整工作流编排。典型示例包括 *AI Scientist-v2* [87] 和 *SimpleDeepSearcher* [69]，它们在开放场景下显著提升了智能体的鲁棒性。
讨论。最优化方法通常与架构选择相辅相成：单智能体系统倾向于使用强化学习实现端到端的奖励对齐，而多智能体系统则更受益于模块化训练和智能体级别的反馈。一些近期的框架，如 *AgentLab* [58]，开始探索结合符号规划、搜索增强和人机协同反馈的混合最优化方法。

表 5. 核心深度研究模块在主要基准上的覆盖情况。P：**规划**，QD：**问题构建**，WE：**网络探索**，RG：**报告生成**。

Benchmark	P	QD	WE	RG	Task	Evaluation Metrics
Mind2Web 2 [19]	✓	✓	✓	✗	Web search	Success rate, Partial Completion
BrowseComp [76]	✓	✓	✓	✗	Web search	Accuracy, Calibration Error
WebArena [101]	✓	✓	✓	✗	Web search	Success Rate
GAIA [40]	✓	✓	✓	✗	Multi-step assistant tasks	EM
Humanity’s Last Exam [48]	✓	✓	✓	✗	Multidomain reasoning	Accuracy, Calibration Error
BrowseComp-Zh [100]	✓	✓	✓	✗	Web search in Chinese	Accuracy, Calibration Error
MedBrowseComp [10]	✓	✓	✓	✗	Medical web search	Accuracy
GPQA [53]	✓	✓	✓	✗	Graduate-level QA	Accuracy
InfoDeepSeek [82]	✗	✓	✓	✗	Open-domain QA	Accuracy, Information Accuracy
DeepResearch Bench [16]	✓	✓	✓	✓	Research report generation	Pairwise Agreement Rate, Overall Pearson Correlation
DeepResearchGym [14]	✓	✓	✓	✓	Research task sandbox	KPR, KPC, Precision, Recall, Clarity, Insight

7 基准和评估

为了理解深度研究系统的发展进展与局限性，近期设计了多项基准测试来评估四个核心技术模块：*规划*、*问题构建*、*网络探索*和 *报告生成*。表 5 总结了主要的基准测试及其在深度研究工作流中覆盖的具体模块。根据任务范围，这些基准测试可大致分为两类：**搜索导向型**和 **研究导向型**。

面向搜索的基准主要关注涉及 *Web 探索*和 *问题构建*的信息检索任务，通常在交互式或语言特定的浏览场景中进行。例如，Mind2Web 2 [19] 评估重新表述查询和动态导航网站的能力，而 BrowseComp [76] 和 BrowseComp-Zh [100] 通过准确率和校准误差来评估多语言浏览性能。WebArena [101] 进一步扩展了这一范围，引入需要简单 *规划*组件的结构化任务，例如多步骤目标追踪。然而，这些基准很少涉及最终内容生成，导致 *报告生成*部分评估不足。

面向研究的基准超越了搜索任务，用于评估长程推理、综合能力以及结构化输出生成。这些任务需要在所有四个模块间实现全流程协调。DeepResearch Bench [16] 和 DeepResearch-Gym [14] 是典型代表，涵盖了从 *规划*子任务分解、子查询的 *问题构建*、实时 *网络探索*到最终以研究型报告形式生成 *报告*的全过程。它们提供了清晰度、知识准确率/召回率（KPR/KPC）和一致得分等详细评估指标。MedBrowseComp [10] 将该流水线专门应用于生物医学领域，而 GAIA [40] 在通用助理任务上评估智能体工作流，并实现了全模块覆盖。此外，Humanity's Last Exam [48] 和 GPQA [53] 强调在检索能力极低条件下的 *规划*与 *问题构建*，模拟了开卷但不可搜索的问答场景。

8 局限性和未来方向

尽管取得了令人瞩目的进展，深度研究系统仍处于初级阶段，在架构、可靠性、模态和可扩展性方面面临多重限制。以下是几个关键挑战和未来方向。

多工具集成。当前大多数系统仅依赖传统的搜索引擎作为其主要外部工具，这严重限制了它们对多样化和任务特定知识源的访问。然而，现实世界的研究通常涉及查询 API、解析结构化数据库、浏览代码仓库以及从文档、表格或图表中检索信息。未来的深度研究智能体必须支持对多种异构工具的动态编排，并在每个推理步骤中灵活决定调用哪些工具。

事实性。确保事实一致性是深度研究系统中的一个核心挑战，尤其是在内容从多个来源合成或涉及多步推理时。智能体可能会无意中引入事实错误、过时的陈述或缺乏支持的断言，尤其是在整合不一致来源的内容时。为解决这一问题，未来系统应引入显式的基于事实的机制，例如来源标注、注重事实性的奖励函数以及事后验证模块。

多模态推理能力。当前的流水线几乎完全依赖文本，这使其不适用于需要视觉或多模态理解的领域。科学、医学和工程领域的研究任务通常涉及多种模态，例如图像、文本描述和扫描文档。将深度研究框架扩展至处理和推理多模态输入（包括图像、PDF 和结构化数据）仍然是一个尚未充分探索但至关重要的方向。

工作流设计与模型最优化。有效的深度研究需要智能体协调涉及任务分解、工具使用和综合的复杂工作流。尽管早期系统通常依赖静态提示和硬编码工作流，近期的研究已开始采用更具适应性和 Agentic 的范式，支持动态规划和工具使用。然而，当前方法仍缺乏在不同任务间泛化并随新目标演进的工作流学习机制。在最优化方面，由于计算成本高且奖励信号稀疏，将大型语言模型与这种动态工作流对齐仍然具有挑战性。未来方向可能包括可扩展的训练策略，例如参数高效微调、分阶段或基于课程的预训练，以及由人类或自动化反馈引导的强化学习。

个性化个性化旨在使智能体与用户的目標和偏好保持一致，以提升性能。现有方法缺乏持久的用户建模和动态适应能力，常常将个性化视为次要问题。未来的工作应开发可扩展、注重隐私的用户模型，并结合持续学习，解决过拟合和公平性挑战。

总之，通过更丰富的工具集成、更强的事实基础、多模态扩展以及高效的智能体训练来解决这些局限性，将是实现自主深度研究系统全部潜力的关键。

9 结论

深度研究正在重塑搜索范式，并已成为智能体研究中最具前景的方向之一。在本综述中，我们系统地概述了深度研究流水线，该流水线包含四个核心阶段：规划、问题构建、网络探索和报告生成。针对每个阶段，我们分析了关键技术挑战，并对为解决这些问题而提出的代表性方法进行了分类。此外，我们总结了近期在最优化技术和面向深度研究的基准方面的进展。最后，我们讨论了开放性挑战与有前景的研究方向，旨在为构建更强大且可信赖的深度研究智能体绘制发展路线图。

References

[1] [n. d.]. Bing. https://www.bing.com/

[2] [n. d.]. Google. https://www.google.com/

[3] [n. d.]. X posts. https://x.com/

[4] Tamer Abuelsaad, Deepak Akkil, Prasenjit Dey, Ashish Jagmohan, Aditya Vempaty, and Ravi Kokku. 2024. Agent-e: From autonomous web navigation to foundational design principles in agentic systems. *arXiv preprint arXiv:2407.13032* (2024).

[5] Y Bai, J Zhang, X Lv, L Zheng, S Zhu, L Hou, Y Dong, J Tang, and J LongWriter Li. 2024. Unleashing 10,000+ word generation from long context llms. *arXiv preprint arXiv:2408.07055* (2024).

[6] Bocha AI. n.d.. *Bocha AI Open Platform —Real-Time Search API for AI Applications.* https://open.bochaai.com/ Site copyright notice shows "© 2023–2024"; earliest independent write-up located April 10 2025..

[7] Brave Software. 2022. *Brave Search —Private Search Engine.* Public launch June 2022; privacy-focused search engine continually updated.

[8] Arie Cattan, Alon Jacovi, Ori Ram, Jonathan Herzig, Roee Aharoni, Sasha Goldshtein, Eran Ofek, Idan Szpektor, and Avi Caciularu. 2025. DRAGged into Conflicts: Detecting and Addressing Conflicting Sources in Search-Augmented LLMs. *arXiv preprint arXiv:2506.08500* (2025).

[9] Mingyang Chen, Tianpeng Li, Haoze Sun, Yijie Zhou, Chenzheng Zhu, Haofen Wang, Jeff Z Pan, Wen Zhang, Huajun Chen, Fan Yang, et al. 2025. Learning to reason with search for llms via reinforcement learning. *arXiv preprint arXiv:2503.19470* (2025).

[10] Shan Chen, Pedro Moreira, Yuxin Xiao, Sam Schmidgall, Jeremy Warner, Hugo Aerts, Thomas Hartvigsen, Jack Gallifant, and Danielle S Bitterman. 2025. MedBrowseComp: Benchmarking Medical Deep Research and Computer Use. *arXiv preprint arXiv:2505.14963* (2025).

[11] Zehui Chen, Kuikun Liu, Qiuchen Wang, Jiangning Liu, Wenwei Zhang, Kai Chen, and Feng Zhao. 2024. Mindsearch: Mimicking human minds elicits deep ai searcher. *arXiv preprint arXiv:2407.20183* (2024).

[12] China National Knowledge Infrastructure. 2024. *CNKI AI Academic Research Assistant (XAI).* First public write-up on 6 Feb 2024; version 4.0 announced 21 Jun 2024..

[13] CNKI. n.d.. *CNKI Overseas Homepage.* Copyright notice "1998–" indicates an evolving portal with multiple revisions.

[14] João Coelho, Jingjie Ning, Jingyuan He, Kangrui Mao, Abhijay Paladugu, Pranav Setlur, Jiahe Jin, Jamie Callan, João Magalhães, Bruno Martins, et al. 2025. Deepresearchgym: A free, transparent, and reproducible evaluation sandbox for deep research. *arXiv preprint arXiv:2505.19253* (2025).

[15] Xinbang Dai, Huikang Hu, Yuncheng Hua, Jiaqi Li, Yongrui Chen, Rihui Jin, Nan Hu, and Guilin Qi. 2025. After Retrieval, Before Generation: Enhancing the Trustworthiness of Large Language Models in RAG. *arXiv preprint arXiv:2505.17118* (2025).

[16] Mingxuan Du, Benfeng Xu, Chiwei Zhu, Xiaorui Wang, and Zhendong Mao. 2025. DeepResearch Bench: A Comprehensive Benchmark for Deep Research Agents. *arXiv preprint arXiv:2506.11763* (2025).

[17] Lutfi Eren Erdogan, Nicholas Lee, Sehoon Kim, Suhong Moon, Hiroki Furuta, Gopala Anumanchipalli, Kurt Keutzer, and Amir Gholami. 2025. Plan-and-act: Improving planning of agents for long-horizon tasks. *arXiv preprint arXiv:2503.09572* (2025).

[18] Google. 2024. *Gemini Deep Research — Your Personal Research Assistant.* Feature announced December 11 2024, see TechCrunch coverage.

[19] Boyu Gou, Zanming Huang, Yuting Ning, Yu Gu, Michael Lin, Weijian Qi, Andrei Kopanev, Botao Yu, Bernal Jiménez Gutiérrez, Yiheng Shu, et al. 2025. Mind2Web 2: Evaluating Agentic Search with Agent-as-a-Judge. *arXiv preprint arXiv:2506.21506* (2025).

[20] Yu Gu, Kai Zhang, Yuting Ning, Boyuan Zheng, Boyu Gou, Tianci Xue, Cheng Chang, Sanjari Srivastava, Yanan Xie, Peng Qi, et al. 2024. Is your llm secretly a world model of the internet? model-based planning for web agents. *arXiv preprint arXiv:2411.06559* (2024).

[21] Yu Gu, Boyuan Zheng, Boyu Gou, Kai Zhang, Cheng Chang, Sanjari Srivastava, Yanan Xie, Peng Qi, Huan Sun, and Yu Su. 2025. Simulate Before Act: Model-Based Planning for Web Agents. *openreview* (2025).

[22] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. 2025. Deepseek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. *arXiv preprint arXiv:2501.12948* (2025).

[23] Rujun Han, Yuhao Zhang, Peng Qi, Yumo Xu, Jenyuan Wang, Lan Liu, William Yang Wang, Bonan Min, and Vittorio Castelli. 2024. RAG-QA Arena: Evaluating Domain Robustness for Long-form Retrieval Augmented Question Answering. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. 4354–4374.

[24] Hongliang He, Wenlin Yao, Kaixin Ma, Wenhao Yu, Yong Dai, Hongming Zhang, Zhenzhong Lan, and Dong Yu. 2024. WebVoyager: Building an end-to-end web agent with large multimodal models. *arXiv preprint arXiv:2401.13919* (2024).

[25] Lisheng Huang, Yichen Liu, Jinhao Jiang, Rongxiang Zhang, Jiahao Yan, Junyi Li, and Wayne Xin Zhao. 2025. ManuSearch: Democratizing Deep Search in Large Language Models with a Transparent and Open Multi-Agent Framework. *arXiv preprint arXiv:2505.18105* (2025).

[26] Yuxuan Huang, Yihang Chen, Haozheng Zhang, Kang Li, Meng Fang, Linyi Yang, Xiaoguang Li, Lifeng Shang, Songcen Xu, Jianye Hao, et al. 2025. Deep Research Agents: A Systematic Examination And Roadmap. *arXiv preprint arXiv:2506.18096* (2025).

[27] Yukun Huang, Yixin Liu, Raghuveer Thirukovalluru, Arman Cohan, and Bhuwan Dhingra. 2024. Calibrating long-form generations from large language models. *arXiv preprint arXiv:2402.06544* (2024).

[28] Ziyang Huang, Xiaowei Yuan, Yiming Ju, Jun Zhao, and Kang Liu. 2025. Reinforced Internal-External Knowledge Synergistic Reasoning for Efficient Adaptive Search Agent. *arXiv preprint arXiv:2505.07596* (2025).

[29] Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel, and Edouard Grave. 2023. Atlas: Few-shot learning with retrieval augmented language models. *Journal of Machine Learning Research* 24, 251 (2023), 1–43.

[30] Pengcheng Jiang, Jiacheng Lin, Lang Cao, Runchu Tian, SeongKu Kang, Zifeng Wang, Jimeng Sun, and Jiawei Han. 2025. Deepretrieval: Hacking real search engines and retrievers with large language models via reinforcement learning. *arXiv preprint arXiv:2503.00223* (2025).

[31] Bowen Jin, Hansi Zeng, Zhenrui Yue, Jinsung Yoon, Sercan Arik, Dong Wang, Hamed Zamani, and Jiawei Han. 2025. Search-r1: Training llms to reason and leverage search engines with reinforcement learning. *arXiv preprint arXiv:2503.09516* (2025).

[32] Michael Katz, Harsha Kokel, Kavitha Srinivas, and Shirin Sohrabi Araghi. 2024. Thought of search: Planning with language models through the lens of efficiency. *Advances in Neural Information Processing Systems* 37 (2024), 138491–138568.

[33] Kyu Won Kim, Suhwan Choi, and Myeongho Jeon. [n. d.]. Say as It Is: Verbatim Fidelity Evaluation of Long-Context Language Model. In *ICML 2025 Workshop on Long-Context Foundation Models*.

[34] Hugo Laurençon, Léo Tronchon, and Victor Sanh. 2024. Unlocking the conversion of web screenshots into html code with the websight dataset. *arXiv preprint arXiv:2403.09029* (2024).

[35] Xiaoxi Li, Guanting Dong, Jiajie Jin, Yuyao Zhang, Yujia Zhou, Yutao Zhu, Peitian Zhang, and Zhicheng Dou. 2025. Search-o1: Agentic search-enhanced large reasoning models. *arXiv preprint arXiv:2501.05366* (2025).

[36] Xiaoxi Li, Jiajie Jin, Guanting Dong, Hongjin Qian, Yutao Zhu, Yongkang Wu, Ji-Rong Wen, and Zhicheng Dou. 2025. Webthinker: Empowering large reasoning models with deep research capability. *arXiv preprint arXiv:2504.21776* (2025).

[37] Jiarun Liu, Jia Hao, Chunhong Zhang, and Zheng Hu. 2025. Wepo: Web element preference optimization for llm-based web navigation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39. 26614–26622.

[38] Do Xuan Long, Duong Ngoc Yen, Do Xuan Trong, Luu Anh Tuan, Kenji Kawaguchi, Shafiq Joty, Min-Yen Kan, and Nancy F Chen. 2025. Beyond In-Context Learning: Aligning Long-form Generation of Large Language Models via Task-Inherent Attribute Guidelines. *arXiv preprint arXiv:2506.01265* (2025).

[39] Chris Lu, Cong Lu, Robert Tjarko Lange, Jakob Foerster, Jeff Clune, and David Ha. 2024. The ai scientist: Towards fully automated open-ended scientific discovery. *arXiv preprint arXiv:2408.06292* (2024).

[40] Grégoire Mialon, Clémentine Fourrier, Thomas Wolf, Yann LeCun, and Thomas Scialom. 2023. Gaia: a benchmark for general ai assistants. In *The Twelfth International Conference on Learning Representations*.

[41] Reiichiro Nakano, Jacob Hilton, Suchir Balaji, Jeff Wu, Long Ouyang, Christina Kim, Christopher Hesse, Shantanu Jain, Vineet Kosaraju, William Saunders, et al. 2021. Webgpt: Browser-assisted question-answering with human feedback. *arXiv preprint arXiv:2112.09332* (2021).

[42] Xuan-Phi Nguyen, Shrey Pandit, Senthil Purushwalkam, Austin Xu, Hailin Chen, Yifei Ming, Zixuan Ke, Silvio Savarese, Caiming Xong, and Shafiq Joty. 2024. Sfr-rag: Towards contextually faithful llms. *arXiv preprint arXiv:2409.09916* (2024).

[43] OpenAI. 2023. GPT-4 Technical Report. *arXiv preprint arXiv:2303.08774* (2023).

[44] OpenAI. 2025. *Introducing Deep Research*.

[45] Ajay Patel, Markus Hofmarcher, Claudiu Leoveanu-Condrei, Marius-Constantin Dinu, Chris Callison-Burch, and Sepp Hochreiter. 2024. Large language models can self-improve at web agent tasks. *arXiv preprint arXiv:2405.20309* (2024).

[46] Perplexity Team. 2025. *Introducing Perplexity Deep Research*.

[47] Chau Pham, Simeng Sun, and Mohit Iyyer. 2024. Suri: Multi-constraint Instruction Following in Long-form Text Generation. In *Findings of the Association for Computational Linguistics: EMNLP 2024*. 1722–1753.

[48] Long Phan, Alice Gatti, Ziwen Han, Nathaniel Li, Josephina Hu, Hugh Zhang, Chen Bo Calvin Zhang, Mohamed Shaaban, John Ling, Sean Shi, et al. 2025. Humanity's last exam. *arXiv preprint arXiv:2501.14249* (2025).

[49] Bowen Ping, Jiali Zeng, Fandong Meng, Shuo Wang, Jie Zhou, and Shanghang Zhang. 2025. LongDPO: Unlock Better Long-form Generation Abilities for LLMs via Critique-augmented Stepwise Information. *arXiv preprint arXiv:2502.02095* (2025).

[50] Zehan Qi, Rongwu Xu, Zhijiang Guo, Cunxiang Wang, Hao Zhang, and Wei Xu. 2024. LONG2RAG: Evaluating Long-Context & Long-Form Retrieval-Augmented Generation with Key Point Recall. In *Findings of the Association for Computational Linguistics: EMNLP 2024*. 4852–4872.

[51] Hongjin Qian and Zheng Liu. 2025. Scent of Knowledge: Optimizing Search-Enhanced Reasoning with Information Foraging. *arXiv preprint arXiv:2505.09316* (2025).

[52] Shuofei Qiao, Runnan Fang, Ningyu Zhang, Yuqi Zhu, Xiang Chen, Shumin Deng, Yong Jiang, Pengjun Xie, Fei Huang, and Huajun Chen. 2024. Agent planning with world knowledge model. *Advances in Neural Information Processing Systems* 37 (2024), 114843–114871.

[53] David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R Bowman. 2024. Gpqa: A graduate-level google-proof q&a benchmark. In *First Conference on Language Modeling*.

[54] Reportify. n.d.. *Reportify — AI Platform for Investment Research*. Continuously updated product site; no formal release date displayed.

[55] Leonard Richardson. 2025. *Beautiful Soup – HTML/XML parsing and screen-scraping library*. https://pypi.org/project/beautifulsoup4/ MIT License. Accessed 2025-06-26.

[56] Alireza Salemi, Julian Killingback, and Hamed Zamani. 2025. ExPerT: Effective and Explainable Evaluation of Personalized Long-Form Text Generation. *arXiv preprint arXiv:2501.14956* (2025).

[57] Samuel Schmidgall and Michael Moor. 2025. Agentrxiv: Towards collaborative autonomous research. *arXiv preprint arXiv:2503.18102* (2025).

[58] Samuel Schmidgall, Yusheng Su, Ze Wang, Ximeng Sun, Jialian Wu, Xiaodong Yu, Jiang Liu, Zicheng Liu, and Emad Barsoum. 2025. Agent laboratory: Using llm agents as research assistants. *arXiv preprint arXiv:2501.04227* (2025).

[59] Scrapy developers. 2025. *Scrapy – A fast, high-level web-crawling & scraping framework*. https://github.com/scrapy/scrapy BSD 3-Clause License. Accessed 2025-06-26.

[60] Selenium contributors. 2025. *Selenium WebDriver – Browser-automation framework*. https://pypi.org/project/selenium/ Apache 2.0 License. Accessed 2025-06-26.

[61] Kwangwook Seo, Donguk Kwon, and Dongha Lee. 2025. Mt-raig: Novel benchmark and evaluation framework for retrieval-augmented insight generation over multiple tables. *arXiv preprint arXiv:2502.11735* (2025).

[62] Yu Shang, Yu Li, Keyu Zhao, Likai Ma, Jiahe Liu, Fengli Xu, and Yong Li. 2024. Agentsquare: Automatic llm agent search in modular design space. *arXiv preprint arXiv:2410.06153* (2024).

[63] Haiyang Shen, Hang Yan, Zhongshi Xing, Mugeng Liu, Yue Li, Zhiyang Chen, Yuxiang Wang, Jiuzheng Wang, and Yun Ma. 2025. RAGSynth: Synthetic Data for Robust and Faithful RAG Component Optimization. *arXiv preprint arXiv:2505.10989* (2025).

[64] Weijia Shi, Xiaochuang Han, Mike Lewis, Yulia Tsvetkov, Luke Zettlemoyer, and Wen-tau Yih. 2024. Trusting your evidence: Hallucinate less with context-aware decoding. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 2: Short Papers)*. 783–791.

[65] Yaorui Shi, Shihan Li, Chang Wu, Zhiyuan Liu, Junfeng Fang, Hengxing Cai, An Zhang, and Xiang Wang. 2025. Search and Refine During Think: Autonomous Retrieval-Augmented Reasoning of LLMs. *arXiv preprint arXiv:2505.11277* (2025).

[66] Huatong Song, Jinhao Jiang, Yingqian Min, Jie Chen, Zhipeng Chen, Wayne Xin Zhao, Lei Fang, and Ji-Rong Wen. 2025. R1-searcher: Incentivizing the search capability in llms via reinforcement learning. *arXiv preprint arXiv:2503.05592* (2025).

[67] Raphael Sourty. 2024. DuckSearch, efficient search with DuckDB. https://github.com/lightonai/ducksearch

[68] Hao Sun, Zile Qiao, Jiayan Guo, Xuanbo Fan, Yingyan Hou, Yong Jiang, Pengjun Xie, Yan Zhang, Fei Huang, and Jingren Zhou. 2025. Zerosearch: Incentivize the search capability of llms without searching. *arXiv preprint arXiv:2505.04588* (2025).

[69] Shuang Sun, Huatong Song, Yuhao Wang, Ruiyang Ren, Jinhao Jiang, Junjie Zhang, Fei Bai, Jia Deng, Wayne Xin Zhao, Zheng Liu, et al. 2025. Simpledeepsearcher: Deep information seeking via web-powered reasoning trajectory synthesis. *arXiv preprint arXiv:2505.16834* (2025).

[70] Manveer Singh Tamber, Forrest Sheng Bao, Chenyu Xu, Ge Luo, Suleman Kazi, Minseok Bae, Miaoran Li, Ofer Mendelevitch, Renyi Qu, and Jimmy Lin. 2025. Benchmarking LLM Faithfulness in RAG with Evolving Leaderboards. *arXiv preprint arXiv:2505.04847* (2025).

[71] Brandon Trabucco, Gunnar Sigurdsson, Robinson Piramuthu, and Ruslan Salakhutdinov. 2025. Towards Internet-Scale Training For Agents. *arXiv preprint arXiv:2502.06776* (2025).

[72] Jonas Wallat, Maria Heuss, Maarten de Rijke, and Avishek Anand. 2024. Correctness is not Faithfulness in RAG Attributions. *arXiv preprint arXiv:2412.18004* (2024).

[73] Kaiyang Wan, Honglin Mu, Rui Hao, Haoran Luo, Tianle Gu, and Xiuying Chen. 2025. A cognitive writing perspective for constrained long-form text generation. *arXiv preprint arXiv:2502.12568* (2025).

[74] Hongru Wang, Cheng Qian, Wanjun Zhong, Xiusi Chen, Jiahao Qiu, Shijue Huang, Bowen Jin, Mengdi Wang, Kam-Fai Wong, and Heng Ji. 2025. Acting Less is Reasoning More! Teaching Model to Act Efficiently. *arXiv preprint arXiv:2504.14870* (2025).

[75] Qiuchen Wang, Ruixue Ding, Yu Zeng, Zehui Chen, Lin Chen, Shihang Wang, Pengjun Xie, Fei Huang, and Feng Zhao. 2025. VRAG-RL: Empower Vision-Perception-Based RAG for Visually Rich Information Understanding via Iterative Reasoning with Reinforcement Learning. *arXiv preprint arXiv:2505.22019* (2025).

[76] Jason Wei, Zhiqing Sun, Spencer Papay, Scott McKinney, Jeffrey Han, Isa Fulford, Hyung Won Chung, Alex Tachard Passos, William Fedus, and Amelia Glaese. 2025. Browsecomp: A simple yet challenging benchmark for browsing agents. *arXiv preprint arXiv:2504.12516* (2025).

[77] Jinming Wu, Zihao Deng, Wei Li, Yiding Liu, Bo You, Bo Li, Zejun Ma, and Ziwei Liu. 2025. MMSearch-R1: Incentivizing LMMs to Search. arXiv:2506.20670 [cs.CV] https://arxiv.org/abs/2506.20670

[78] Siwei Wu, Yizhi Li, Xingwei Qu, Rishi Ravikumar, Yucheng Li, Tyler Loakman, Shanghaoran Quan, Xiaoyong Wei, Riza Batista-Navarro, and Chenghua Lin. 2025. Longeval: A comprehensive analysis of long-text generation through a plan-based paradigm. *arXiv preprint arXiv:2502.19103* (2025).

[79] Shirley Wu, Shiyu Zhao, Qian Huang, Kexin Huang, Michihiro Yasunaga, Kaidi Cao, Vassilis Ioannidis, Karthik Subbian, Jure Leskovec, and James Y Zou. 2024. Avatar: Optimizing llm agents for tool usage via contrastive reasoning. *Advances in Neural Information Processing Systems* 37 (2024), 25981–26010.

[80] Weiqi Wu, Xin Guan, Shen Huang, Yong Jiang, Pengjun Xie, Fei Huang, Jiuxin Cao, Hai Zhao, and Jingren Zhou. 2025. MASKSEARCH: A Universal Pre-Training Framework to Enhance Agentic Search Capability. *arXiv preprint arXiv:2505.20285* (2025).

[81] xAI. 2025. *Grok 3 Beta — The Age of Reasoning Agents.*

[82] Yunjia Xi, Jianghao Lin, Menghui Zhu, Yongzhao Xiao, Zhuoying Ou, Jiaqi Liu, Tong Wan, Bo Chen, Weiwen Liu, Yasheng Wang, et al. 2025. InfoDeepSeek: Benchmarking Agentic Information Seeking for Retrieval-Augmented Generation. *arXiv preprint arXiv:2505.15872* (2025).

[83] Weimin Xiong, Yifan Song, Qingxiu Dong, Bingchan Zhao, Feifan Song, Xun Wang, and Sujian Li. 2025. Mpo: Boosting llm agents with meta plan optimization. *arXiv preprint arXiv:2503.02682* (2025).

[84] Renjun Xu and Jingwen Peng. 2025. A Comprehensive Survey of Deep Research: Systems, Methodologies, and Applications. *arXiv preprint arXiv:2506.12594* (2025).

[85] Shicheng Xu, Liang Pang, Huawei Shen, Xueqi Cheng, and Tat-Seng Chua. 2024. Search-in-the-chain: Interactively enhancing large language models with search for knowledge-intensive tasks. In *Proceedings of the ACM Web Conference 2024*. 1362–1373.

[86] Yunqi Xu, Tianchi Cai, Jiyan Jiang, and Xierui Song. 2024. Face4RAG: Factual Consistency Evaluation for Retrieval Augmented Generation in Chinese. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 6083–6094.

[87] Yutaro Yamada, Robert Tjarko Lange, Cong Lu, Shengran Hu, Chris Lu, Jakob Foerster, Jeff Clune, and David Ha. 2025. The ai scientist-v2: Workshop-level automated scientific discovery via agentic tree search. *arXiv preprint arXiv:2504.08066* (2025).

[88] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. 2025. Qwen3 Technical Report. *arXiv preprint arXiv:2505.09388* (2025).

[89] Tiannuo Yang, Zebin Yao, Bowen Jin, Lixiao Cui, Yusen Li, Gang Wang, and Xiaoguang Liu. 2025. Demystifying and Enhancing the Efficiency of Large Language Model Based Search Agents. *arXiv preprint arXiv:2505.12065* (2025).

[90] Zhengyuan Yang, Linjie Li, Jianfeng Wang, Kevin Lin, Ehsan Azarnasab, Faisal Ahmed, Zicheng Liu, Ce Liu, Michael Zeng, and Lijuan Wang. 2023. Mm-react: Prompting chatgpt for multimodal reasoning and action. *arXiv preprint arXiv:2303.11381* (2023).

[91] Jiahao Ying, Yixin Cao, Kai Xiong, Yidong He, Long Cui, and Yongbin Liu. 2023. Intuitive or Dependent? Investigating LLMs' Behavior Style to Conflicting Prompts. *arXiv preprint arXiv:2309.17415* (2023).

[92] Xiaowei Yuan, Zhao Yang, Yequan Wang, Shengping Liu, Jun Zhao, and Kang Liu. 2024. Discerning and resolving knowledge conflicts through adaptive decoding with contextual information-entropy constraint. *arXiv preprint arXiv:2402.11893* (2024).

[93] Dingchu Zhang, Yida Zhao, Jialong Wu, Baixuan Li, Wenbiao Yin, Liwen Zhang, Yong Jiang, Yufeng Li, Kewei Tu, Pengjun Xie, et al. 2025. EvolveSearch: An Iterative Self-Evolving Search Agent. *arXiv preprint arXiv:2505.22501* (2025).

[94] Qinggang Zhang, Zhishang Xiang, Yilin Xiao, Le Wang, Junhui Li, Xinrun Wang, and Jinsong Su. 2025. FaithfulRAG: Fact-Level Conflict Modeling for Context-Faithful Retrieval-Augmented Generation. *arXiv preprint arXiv:2506.08938* (2025).

[95] Wenlin Zhang, Xiangyang Li, Kuicai Dong, Yichao Wang, Pengyue Jia, Xiaopeng Li, Yingyi Zhang, Derong Xu, Zhaocheng Du, Huifeng Guo, et al. 2025. Process vs. Outcome Reward: Which is Better for Agentic RAG Reinforcement Learning. *arXiv preprint arXiv:2505.14069* (2025).

[96] Yao Zhang, Zijian Ma, Yunpu Ma, Zhen Han, Yu Wu, and Volker Tresp. 2025. Webpilot: A versatile and autonomous multi-agent system for web task execution with strategic exploration. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39. 23378–23386.

[97] Qingfei Zhao, Ruobing Wang, Dingling Xu, Daren Zha, and Limin Liu. 2025. R-Search: Empowering LLM Reasoning with Search via Multi-Reward Reinforcement Learning. *arXiv preprint arXiv:2506.04185* (2025).

[98] Yuxiang Zheng, Dayuan Fu, Xiangkun Hu, Xiaojie Cai, Lyumanshan Ye, Pengrui Lu, and Pengfei Liu. 2025. Deepresearcher: Scaling deep research via reinforcement learning in real-world environments. *arXiv preprint arXiv:2504.03160* (2025).

[99] Yuxiang Zheng, Shichao Sun, Lin Qiu, Dongyu Ru, Cheng Jiayang, Xuefeng Li, Jifan Lin, Binjie Wang, Yun Luo, Renjie Pan, et al. 2024. OpenResearcher: Unleashing AI for Accelerated Scientific Research. *arXiv preprint arXiv:2408.06941* (2024).

[100] Peilin Zhou, Bruce Leon, Xiang Ying, Can Zhang, Yifan Shao, Qichen Ye, Dading Chong, Zhiling Jin, Chenxuan Xie, Meng Cao, et al. 2025. Browsecomp-zh: Benchmarking web browsing ability of large language models in chinese. *arXiv preprint arXiv:2504.19314* (2025).

[101] Shuyan Zhou, Frank F Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Tianyue Ou, Yonatan Bisk, Daniel Fried, et al. 2023. Webarena: A realistic web environment for building autonomous agents. *arXiv preprint arXiv:2307.13854* (2023).

[102] Wenxuan Zhou, Sheng Zhang, Hoifung Poon, and Muhao Chen. 2023. Context-faithful Prompting for Large Language Models. *Findings of the Association for Computational Linguistics: EMNLP 2023* (2023).