華中科技大學

本科生毕业设计（论文）开题报告

题目：基于检索增强生成技术的深度研究智能体系统设计与实现

院　　系	计算机科学与技术
专业班级	计科 2204
姓　　名	蔡毅平
学　　号	U202215452
指导教师	李国宽

2026 年 03 月

开题报告填写要求

一、 开题报告主要内容：

1. 课题来源、目的及意义；
2. 国内外研究现况及发展趋势；
3. 课题研究的内容和技术方案；
4. 可行性与风险分析；
5. 课题研究进度安排；
6. 主要参考文献。

二、 报告内容用小四号宋体字编辑，采用 A4 号纸双面打印，封面与封底采用浅蓝色封面纸（卡纸）打印。要求内容明确，语句通顺。

三、 指导教师评语、教研室（系、所）或开题报告答辩小组审核意见用蓝、黑钢笔手写或小四号宋体字编辑，签名必须手写。

四、 理、工、医类要求字数在 3000 字左右，文、管类要求字数在 2000 字左右。

五、 开题报告应在第八学期第二周之前完成。

1 课题来源、目的及意义

1.1 课题来源

本课题来源于华中科技大学武汉光电国家研究中心并行数据存储实验室（PDSL）实验项目。

近年来，大语言模型（Large Language Models, LLM）在自然语言理解与生成任务中取得了显著进展。以 GPT 系列[1]、DeepSeek 系列[2] 及 Qwen 系列[3] 为代表的通用语言模型，在问答、文本生成与知识推理等任务中展现出强大能力，逐渐成为构建通用语言智能体的重要基础。然而，此类模型的知识来源受限于训练阶段的静态参数记忆，存在固有的时效性局限；加之生成过程缺乏对真实知识来源的直接约束，模型在面对动态更新信息或专业领域任务时，仍容易产生事实性错误乃至“幻觉”（hallucination）问题[4]。

为克服上述局限性，检索增强生成（Retrieval-Augmented Generation, RAG）方法被提出并得到广泛应用[5]。该方法将大规模知识文档编码为稠密向量并存入向量数据库，推理时通过向量相似度检索高相关性文档，以此引导模型的生成过程。尽管 RAG 框架显著提升了输出的事实准确性与领域适应性，但其本质上仍将模型限制为对知识库内容的被动消费，难以支持更深层次的探索性推理与主动知识获取。

随着大模型在规划、工具调用与反思性推理[6-7] 等智能体能力上的持续增强，一种从被动检索向主动、目标驱动的知识交互模式转变的趋势愈发明显。在此背景下，深度研究（Deep Research）范式应运而生[8]。该范式通过“规划 → 问题生成 → 网页搜索 → 报告生成”四个相互关联的阶段[9]，使智能体能够自主规划研究路径、动态扩充知识来源，从而对目标领域进行系统、深入的分析与推理。

然而，深度研究范式在提升语料广度的同时，也引入了新的挑战：大规模网页搜索与文本提炼压缩过程带来较高的时间延迟与调用开销，且难以保证所获语料与研究主题在相关性与深度上的一致性。

鉴于此，本课题提出将 RAG 框架的向量检索机制引入深度研究智能体，通过将结构化本地知识库与主动网络搜索有机结合，兼顾检索精准性与知识来源

广泛性，以期在提升报告生成效率的同时，进一步保障输出内容的相关性与质量。

1.2 课题目的及意义

1.2.1 课题目的

本课题旨在将 RAG 框架与深度研究范式相融合，构建一种兼具检索精准性与知识探索主动性的增强型深度研究智能体系统。具体目标包括以下三点：

1. 通过引入本地向量知识库，降低深度研究范式对网络搜索的过度依赖，有效减少端到端的时间延迟与搜索调用开销；

2. 在保留深度研究范式广泛知识获取能力的基础上，借助向量相似度检索机制对上下文进行精准压缩，从而降低长上下文窗口带来的计算负担；

3. 通过本课题的研究与实践，加深对深度研究范式和 RAG 框架的系统理解，厘清两种架构各自的适用场景、核心特点与局限所在。

1.2.2 课题意义

理论意义：现有研究多将 RAG 与智能体能力分开讨论，鲜有工作在深度研究范式框架下对二者进行系统性整合[10]。本课题尝试弥合这一研究空白，为“检索—推理—生成”一体化的智能体架构提供新的设计思路，有助于丰富 RAG 方法在智能体场景下的应用理论。

实践意义：深度研究范式在学术调研、行业分析、知识问答等场景中具有广泛应用潜力，但高延迟与长上下文窗口需求制约了其实际落地。本课题所提方法可有效提升此类系统的实用性，对构建高质量、高效率的智能研究助手具有直接的参考价值。

2 国内外研究现况及发展趋势

2.1 深度研究智能体（Deep Research Agents）的发展

深度研究范式旨在模拟人类研究员的思维模式，通过多步规划、问题生成、网页搜索、报告合成，实现对所给命题的系统化分析。目前主要以工业界产品的形态出现，学术界围绕其核心模块也展开了系列研究。

（1）核心模块

深度研究范式通常由四个相互关联的核心模块构成（见图 1），各模块的功能和主要实现方法如下：

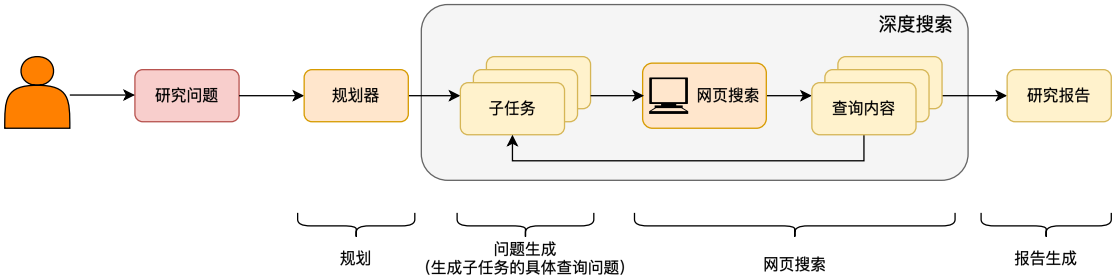

图 1 深度研究系统概述

规划模块：负责将用户的高层次研究问题转化为包含中间子目标的结构化研究计划，其作用在于克服纯粹的提示词的局限，通过明确的任务分解引导后续检索与推理，提升长程一致性与可解释性。

问题生成模块：负责将规划阶段的子目标转化为一系列具体的检索查询任务，是智能体探索信息空间的关键线索，直接决定后续检索的覆盖率与准确性。

网络搜索模块：负责根据查询任务从外部来源检索相关信息，是深度研究智能体获取实时、广域知识的核心通道。

报告生成模块：负责将零散的多源检索结果整合为结构连贯、事实可靠的长文本研究报告，是深度研究智能体面向用户的最终输出环节。

（2）主流系统与产品

OpenAI 在 2025 年推出的 DeepResearch 功能[11] 以 o3 模型为核心，通过多轮自主网络搜索、信息筛选与结构化报告生成，展现了智能体在复杂信息综合任务上的能力边界。这类智能体不仅针对网页浏览进行了专门优化，还通过端到

端强化学习训练，使其能够在处理长达数十分钟的任务时，自主规划并执行多步骤轨迹来查找所需的数据。其核心优势在于能够利用强大的底层推理能力进行“反思性搜索”，即根据前一次搜索获取的信息动态调整后续的检索策略，从而触达互联网长尾中的关键证据。然而，此类方案也面临显著的挑战，主要体现在高昂的计算成本与推理延迟，且其闭源特性限制了在私有知识库场景下的灵活部署。

与之相对，斯坦福大学提出的 STORM（Synthesis of Topic Outlines through Retrieval and Multi-perspective Question Asking）架构[12] 则侧重于从多维度视角构建知识大纲。该系统的研究核心在于优化智能体提出正确问题的能力。通过“观点引导式提问”和“模拟对话”两种机制确保了研究内容的覆盖广度。除此之外，STORM 创新性地将研究过程结构化为预写（Pre-writing）与写作（Writing）两个阶段，有效缓解了生成式模型常见的逻辑破碎问题。但在实际应用中，STORM 的局限性在于其对外部实时信息的整合速度较慢，且对复杂多模态数据的处理能力尚显不足。

MindSearch[13] 提出了一种模拟人类思维方式的多智能体搜索架构，将研究任务分解为动态图结构中的子问题，由规划智能体与搜索智能体协同完成。其创新之处在于将任务分解的过程显式建模为有向无环图（DAG），使中间推理步骤具有可解释性，并支持并行子任务的调度执行，显著提升了复杂问题的处理效率。不足之处在于多智能体间的协调开销较大，且图结构的质量高度依赖初始规划阶段的准确性，规划错误会在后续环节中级联传播。

（3）主要局限性

综合现有深度研究系统的研究进展，当前范式存在一些核心局限。

首先，现有深度研究系统几乎全部依赖公开网络搜索作为唯一外部知识来源，无法有效利用用户私有文档、企业内部知识库等非公开资源，制约了其在专业领域的适用性。其次，现有的系统在跨文档、多跳推理等复杂场景中难以保持事实一致性，尤其是在整合相互矛盾的多源证据时，幻觉问题仍未得到根本解决。

此外，由于深度研究范式往往依赖大量串行网络搜索与内容提炼，导致较高的网络时延与 API 调用成本。更为关键的是，随着对话轮次增加，检索内容

与中间推理结果的累计会使上下文窗口急剧膨胀，而现有的系统缺乏有效的历史知识压缩和按需召回机制。尽管大语言模型的最新进展已经显著扩展了上下文窗口大小，但当前限制仍对涉及极长上下文的任务构成约束，这也成为深度研究智能体亟待克服的挑战之一。

2.2 检索增强生成（RAG）技术的演进

自 2020 年 RAG 技术被首次提出[5] 以来，检索增强生成逐渐成为大语言模型研究的重要方向。该框架通过将文档检索模块与生成模型相结合，使模型能够借助外部知识库生成更具事实依据的回答。此后，大量研究围绕检索策略优化、知识库构建以及生成质量提升等问题持续推进。

2.2.1 基础 RAG 架构

早期基础的 RAG 系统的处理流程主要包含以下四个阶段（见图 2）。

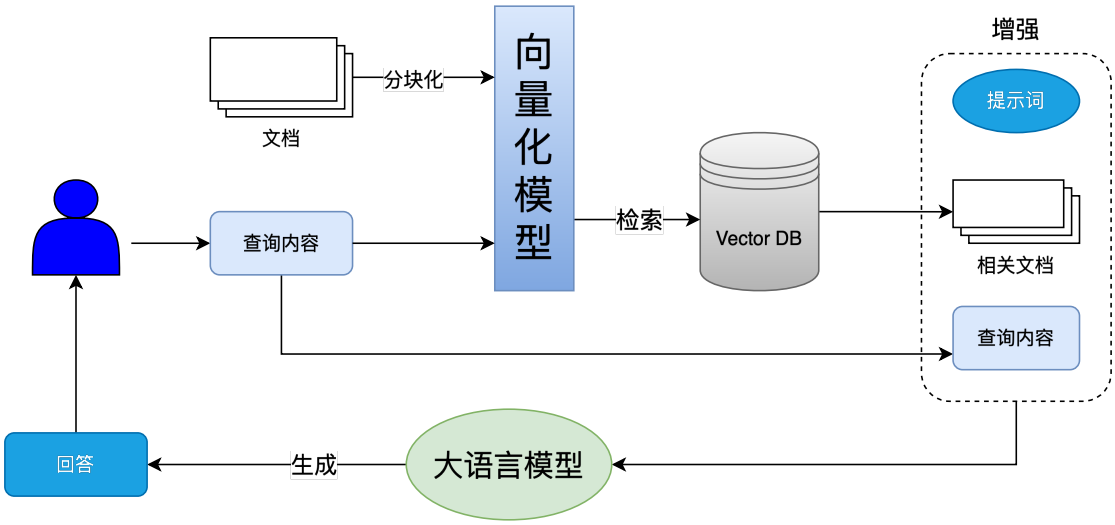

图 2　RAG 系统基础架构概述

（1）**数据索引构建**。对非结构化数据进行清洗与向量化后存入向量数据库，构成 RAG 系统的离线基础。

（2）**检索（Retrieval）阶段**。根据用户输入的查询语句，系统将其转换为同空间的特征向量，通过余弦相似度等距离度量算法计算查询向量 **q** 与索引向量 **d** 之间的相关性，并筛选出相关度最高的若干文本块。

（3）增强（Augmentation）阶段。系统将原始查询与检索到的知识块进行模板化拼接，通过向提示词（prompt）注入外部证据，将生成任务转化为基于事实总结的任务，有效约束了模型的发散性，提升了生成内容的事实准确性。

（4）生成（Generation）阶段。大语言模型接收增强后的提示词，并根据所提供的背景内容生成最终回答。

2.2.2 高级 RAG 架构

目前的 RAG 系统已从上述简单的“检索—增强—生成”架构演进为更为复杂的高级 RAG（Advanced RAG）架构[10]，主要优化方向体现在以下三个维度。

（1）检索前优化。包括查询重写（Query Rewriting），即通过 LLM 将用户模糊的提问转化为更适合向量检索的描述；以及多查询生成，即从不同维度生成多个相关子查询，以覆盖更广泛的语义空间。

（2）检索后处理。如重排序（Reranking）机制——由于文本分块后的向量检索存在一定精度损失，引入交叉编码器（Cross-Encoder）对初步筛选结果进行二次精细排序，确保最相关的上下文排在首位。

（3）架构模块化（Modular RAG）。现代 RAG 系统不再是线性流水线，而是引入了路由（Routing）、调度（Scheduling）与递归检索（Recursive Retrieval）等模块，使系统能够根据问题难度自主决定是否需要多轮检索。

2.2.3 新兴 RAG 框架

在上述优化方向之外，若干新颖的 RAG 框架也在持续涌现。例如，**知识图谱增强（Graph RAG）**[14] 通过构建知识库中实体间的关系图谱，将非结构化知识转化为结构化图索引，实现跨文档的深度关联分析与更高层级的语义概括。**智能体化 RAG（Agentic RAG）**[15] 致力于将 RAG 系统由“静态流程”转变为“主动思考”，让模型自主判断何时需要检索、检索结果是否满足需求，以及是否需要更换检索策略，显著提升了处理复杂推理任务的能力。**多模态 RAG（Multi-modal RAG）**将原有纯文本知识库扩展到图像、音频与视频，通过统一的多模态向量空间，支持直接检索视频片段或图表信息以辅助生成。

2.2.4 RAG 技术的现有局限与特点

综合现有研究可以发现，RAG 技术依赖预构建的静态向量知识库，难以支持知识的实时更新，在面对快速演化的领域知识时存在明显滞后。此外，即便成功检索到相关文档，传统 RAG 系统在将多源信息融入生成过程时仍易产生片段化、不连贯的输出，在多文档跨域综合场景下尤为突出。尽管如此，面对海量数据库时，从成本效益比与推理延迟的角度审视，RAG 仍具有独特优势。

2.3 稠密检索（Dense Retrieval）

在 RAG 架构中，向量检索是从海量非结构化数据中提取关键语义信息的基石。如表 1，相较于传统的基于关键词匹配的稀疏检索，稠密检索[16] 利用深度学习技术将文本映射至连续低维向量空间，从而实现了从“字面匹配”到“语义理解”的跨越。

稠密检索的核心在于稠密嵌入，不同于稀疏嵌入常常生成数万维的向量，稠密向量通常由预训练模型（如 BERT[17]，RoBERTa[18]）生成，维度通常在 768 到 1536 之间，且每一维都携带特定的语义特征。

表 1 稀疏检索与稠密检索方法对比

特性	稀疏检索（BM25[19] / TF-IDF）	稠密检索
表示形式	高维（词表大小），极其稀疏	低维（固定长度），稠密
匹配原理	关键词重合度	潜在语义关联（latent semantic）
优势	解释性强，对专有名词敏感	能处理同义词，支持跨语言检索
劣势	无法处理词汇空缺问题	对训练数据依赖性强，容易产生语义偏移

虽然稠密检索在理解上下文方面具有显著优势，但是在处理精确匹配（如产品型号，特定人名等）时仍不及稀疏检索。

目前工业界和学业届的共识是采用混合检索方案，即同时运行稠密检索和稀疏检索，并通过互惠排名融合（Reciprocal Rank Fusion, RRF）等算法对两路结

果进行合并[20]。这种方式既保留了对长尾语义的捕获能力，又保证了对专有名词的检索精度。

3 研究内容与技术方案

3.1 课题研究内容

本课题以“RAG 增强的深度研究智能体”为核心研究对象，系统研究向量检索机制与深度研究范式的融合方法，具体研究内容包括：基线深度研究智能体系统的设计与实现、RAG 模块的集成方案设计，以及系统整体评估方案的制定。

3.2 课题预期目标

完成一个集成了 RAG 模块的深度研究智能体系统，并且通过评估测试，在具体应用场景下有明显的指标提升。

3.3 技术路线与方案

3.3.1 关键技术

（1）文档解析与知识入库技术。系统需要对多种格式文档进行结构化解析，提取正文、表格、图表等关键信息，并进行文本分块（chunking）处理。分块策略将综合考虑语义完整性与检索效率，采用基于段落边界与滑动窗口相结合的方式，确保每个文本块在语义上自洽。分块完成后，使用预训练的文本嵌入模型将文本块转化为语义向量，写入向量数据库（如 ChromaDB 或 FAISS）构建离线知识索引。

（2）混合检索技术。为兼顾召回率与准确率，系统将采用稠密向量检索与稀疏关键词检索（BM25）相结合的混合检索策略。稠密检索通过余弦相似度计算查询向量与文档向量的语义相似性，能够有效覆盖同义表达与语义相近文本；稀疏检索则对精确词汇匹配具有更高敏感度，适合处理专有名词缩写。两路检索结果将通过互惠排名融合（RRF）算法[20] 或带权重的线性融合进行合并，对文本的相关性进行筛选。

（3）智能体规划与工具调用技术。深度研究范式的核心在于智能体具备自主规划与动态决策的能力。本系统将基于大语言模型的函数调用机制，设计规划与执行两层架构，规划部分负责将用户输入的研究问题分解为有序的子任务列表；执行部分则根据子任务的性质，自主选择调用本地向量检索工具或网络搜索工具，并在获取结果后进行自我反思，判断当前知识是否足以支撑该子问题的答案，从而决定是否发起新一轮检索。

3.3.2 总体方案

系统的总体架构设计分为离线知识入库模块和在线深度研究模块两大部分。离线模块负责文档的解析、分块、向量化与索引构建；在线模块则由规划器、检索执行器（集成本地 RAG 和网络检索）和报告生成器三个子模块组成，共同驱动完整的深度研究流程。整体架构如图 3

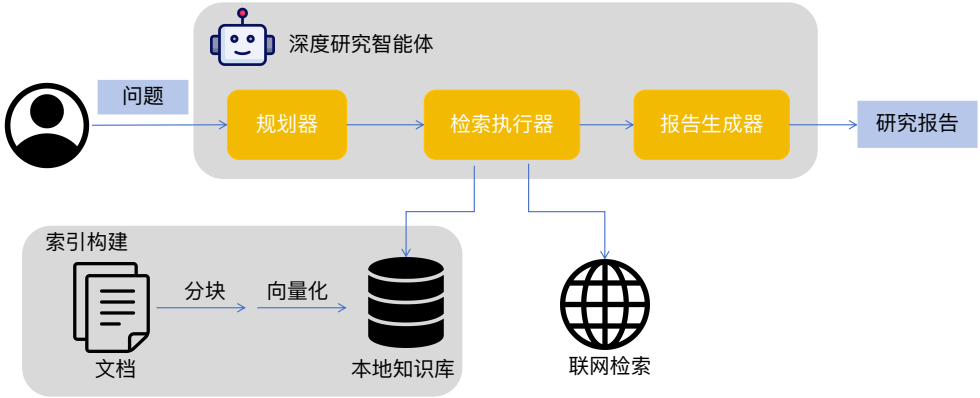

图 3　系统整体架构

用户输入研究主题后。规划器首先生成结构化研究计划，逐步拆解为若干子问题；针对每个子问题，检索执行器优先从本地向量知识库中检索相关文档，当本地知识库覆盖不足时，再调用网络搜索工具补充实时信息；所有检索到的证据经过整合与上下文压缩后，交由报告生成器完成最终报告的输出。

课题的实验评估方案可以围绕具体应用场景，从检索效率和报告生成质量

两个方面进行评估，前者可以通过记录端到端响应时延与 API 调用次数来反映，后者可以通过 benchmark 和人工打分的方案进行衡量。

4 可行性与风险分析

4.1 制约因素与风险

在系统构建过程中，前文所述的技术方案可能存在一些技术风险。

其一，检索质量风险。向量检索的效果高度依赖嵌入模型质量与分块策略的合理性，若分块粒度过细则语义上下文信息可能丢失，若粒度过粗则召回噪声增加；当用户查询与本地知识库语义分布差异较大时，检索召回率可能不达预期，导致系统仍需大量网络搜索，从而影响整体效率提升效果。

其二，多模态内容处理风险。专业文档中往往包含大量图表、公式与结构化表格，现有嵌入模型可能对此类内容的理解与转化能力尚不稳定，存在信息丢失或语义误解风险，影响报告的事实准确性。

其三，系统集成风险。本系统涉及文档解析、向量检索、网络搜索、智能体规划与报告生成多个异构模块协同，模块间的接口设计不当或异常处理缺失可能导致整体流程稳定性不佳。

为应对这些风险，可以在开发过程中首先建立一个最小可用版本，先跑通完整链路，再逐步集成各类工具，这样即使某个模块遇到困难，也可以基本保证整体系统效果。

4.2 成本估算与可行性

从技术角度来看，本课题所涉及的关键技术均已有成熟工具支持，因此整体实现具有较高可行性。当前已有多种文档解析工具能够实现各类结构提取，同时向量数据库与语言模型接口也十分成熟，除此之外，目前也有较为丰富的整体系统设计范式可供参考，这为系统实现提供了良好基础。

本项目属于典型的软件系统开发项目，规模较小，可归类为 COCOMO 模型中的组织型（organic）项目。基本的 COCOMO 模型计算开发工作量的公式如下：

$$MM = r * (KDSI)^c \tag{1}$$

COCOMO 模型为组织型项目提供参数为：r=0.4，c=1.05，a=10.5，b=0.38。根据经验估计，本系统核心代码大约在 4000 行左右，将 KDSI=4 代入以上公式计算可得开发工作量为 1.7（人月），即一人大约需要 1.7 个月完成开发，较为符合毕设时间要求，预计可以按计划完成。

5 课题研究进度安排

由于本课题是一个研究性的课题，构思和实验的进度难以确定。大致的进度安排如表 2所示。

表 2 课题研究进度安排表

月份	工作任务
2026 年 1 月	接受选题，阅读相关文献和技术方案
~2026 年 2 月	进行需求分析与工具调研，完成技术方案设计
2026 年 2 月	完成翻译和开题报告，搭建基础完整链路
~2026 年 4 月	根据方案设计完成系统所有模块
2026 年 5 月	部署到具体环境中进行测试，撰写论文
2026 年 6 月	准备最终答辩

6 参考文献

[1] BROWN T, MANN B, RYDER N, et al. Language Models are Few-Shot Learners [J]. Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.

[2] DeepSeek-AI. DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model[J]. arXiv preprint arXiv:2405.04434, 2024.

[3] BAI J, BAI S, CHU Y, et al. Qwen Technical Report[J]. arXiv preprint arXiv:2309.16609, 2023.

[4] JI Z, LEE N, FRIESKE R, et al. Survey of Hallucination in Natural Language Generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.

[5] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems: vol. 33. 2020: 9459-9474.

[6] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]//International Conference on Learning Representations. 2023.

[7] SHINN N, CASSANO F, GOPINATH A, et al. Reflexion: Language Agents with Verbal Reinforcement Learning[J]. Advances in Neural Information Processing Systems, 2023, 36.

[8] HUANG Y, CHEN Y, ZHANG H, et al. Deep Research Agents: A Systematic Examination And Roadmap[J]. arXiv preprint arXiv:2506.18096, 2025.

[9] ZHANG W, LI X, ZHANG Y, et al. Deep Research: A Survey of Autonomous Research Agents[J/OL]. arXiv preprint arXiv:2508.12752, 2025. arXiv: 2508.12752 [cs.AI].

[10] GAO Y, XIONG Y, GAO X, et al. Retrieval-Augmented Generation for Large Language Models: A Survey[J]. arXiv preprint arXiv:2312.10997, 2023.

[11] OpenAI. Introducing Deep Research[R]. https://openai.com/index/introducing-deep-research/. OpenAI, 2025.

[12] SHAO Y, JIANG Y, KANELL T A, et al. Assisting in Writing Wikipedia-like Articles From Scratch with Large Language Models[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics. 2024: 6252-6278.

[13] CHEN Z, LIU K, WANG Q, et al. MindSearch: Mimicking Human Minds Elicits Deep AI Searcher[J]. arXiv preprint arXiv:2407.20183, 2024.

[14] EDGE D, TRINH H, CHENG N, et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization[J]. arXiv preprint arXiv:2404.16130, 2024.

[15] SINGH A, EHTESHAM A, KUMAR S, et al. Agentic Retrieval-Augmented

Generation: A Survey on Agentic RAG[J/OL]. arXiv preprint arXiv:2501.09136, 2025. DOI: 10.48550/arXiv.2501.09136.

[16] KARPUKHIN V, OĞUZ B, MIN S, et al. Dense Passage Retrieval for Open-Domain Question Answering[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. 2020: 6769-6781.

[17] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of NAACL-HLT 2019. 2019: 4171-4186.

[18] LIU Y, OTT M, GOYAL N, et al. RoBERTa: A Robustly Optimized BERT Pre-training Approach[J/OL]. arXiv preprint arXiv:1907.11692, 2019. arXiv: 1907.11692 [cs.CL].

[19] ROBERTSON S, ZARAGOZA H. The Probabilistic Relevance Framework: BM25 and Beyond[C]//Foundations and Trends in Information Retrieval: vol. 3: 4. Now Publishers, 2009: 333-389.

[20] CORMACK G V, CLARKE C L A, BUETTCHER S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods[C/OL]// Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’09). ACM, 2009: 758-759. DOI: 10.1145/1571941.1572114.

华中科技大学本科生毕业设计（论文）开题报告评审表

姓名	蔡毅平	学号	U202215452	指导教师	李国宽
院（系）专业	计算机科学与技术学院计科 2204				

指导教师评语

1. 学生前期表现情况。
2. 是否具备开始设计（论文）条件？是否同意开始设计（论文）？
3. 不足及建议。

缺乏创新性，后期可以尝试多做一些优化

评　分：_____　　指导教师（签名）：

2026 年 3 月 15 日

教研室（系、所）或开题报告答辩小组审核意见

教研室（系、所）或开题报告答辩小组负责人（签名）：

2026 年 3 月 15 日